Multicolinealidad y Factor de Inflación de la Varianza (VIF)

Robustez y Validación de Modelos - ISIS-2611

Rubén Manrique

Universidad de los Andes

Semestre 2026-10

¿Qué es la Multicolinealidad?

Ocurre cuando dos o más variables independientes en un modelo de regresión están altamente correlacionadas entre sí.

Tipos de Multicolinealidad:

- **Perfecta:** Una variable es una combinación lineal exacta de otras (el modelo no se puede calcular).
- **Alta:** Existe una fuerte correlación, pero no exacta.

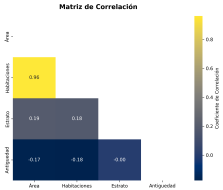

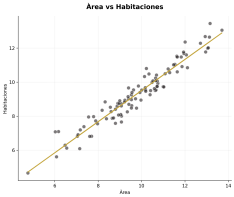

El Problema

Si las variables X_1 y X_2 se mueven siempre juntas, el modelo no puede determinar cuál de las dos es la responsable del cambio en Y. Los coeficientes β se vuelven erráticos e inestables.

Consecuencias en el Modelo

¿Por qué deberíamos preocuparnos por la multicolinealidad si el R^2 sigue siendo alto?

1. **Inestabilidad de Coeficientes:** Pequeños cambios en los datos pueden causar cambios drásticos en los valores de β.
2. **Pérdida de Significancia:** Los errores estándar aumentan significativamente, lo que hace que los p-values suban y las variables parezcan "no importantesçuando sí lo son.
3. **Interpretación Errónea:** Podríamos obtener signos opuestos a la lógica (ej: el precio de una casa bajando cuando aumenta su área).

Factor de Inflación de la Varianza (VIF)

El VIF mide cuánto se ïnfla"la varianza de un coeficiente de regresión estimado debido a la colinealidad.

Fórmula del VIF para la variable X_j

$$VIF_j = \frac{1}{1 - R_j^2}$$

¿Cómo se calcula R_j^2?

1. Tomamos la variable X_j como si fuera la variable dependiente (Y).
2. Hacemos una regresión de X_j contra **todas las demás** variables independientes.
3. El R^2 resultante de esa regresión nos indica qué tan bien es explicada X_j por sus compañeras.

Interpretación de los Valores VIF

Valor VIF	Interpretación
$VIF = 1$	No hay correlación alguna con otros predictores.
$1 < VIF < 5$	Correlación moderada (generalmente aceptable).
$VIF > 5$	Multicolinealidad preocupante. Revisar variables.
$VIF > 10$	Multicolinealidad severa. Se debe eliminar la variable.

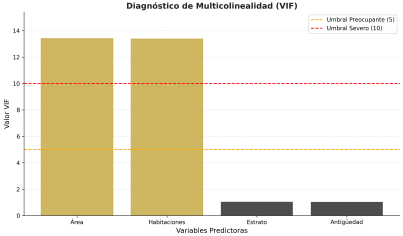

Posibles soluciones:

- Eliminar una de las variables altamente correlacionadas.
- Combinar variables (ej: usar un índice).
- Usar técnicas de Regularización (Ridge/Lasso).

Descomposición del Error de Generalización

Cuando evaluamos un modelo en datos nuevos, el error esperado se puede descomponer en tres fuentes:

Ecuación del Error

$$\text{Error Total} = \underbrace{(\text{Sesgo})^2}_{\text{Error de asunción}} + \underbrace{\text{Varianza}}_{\text{Sensibilidad al ruido}} + \underbrace{\text{Error Irreducible}}_{\text{Ruido inherente del sistema}}$$

Alto Sesgo (Underfitting):

- El modelo $h_\theta(x)$ es demasiado simple para capturar la estructura de los datos.
- $J(\theta)_{train} \approx J(\theta)_{test}$ (ambos altos).

Alta Varianza (Overfitting):

- El modelo $h_\theta(x)$ es excesivamente complejo y memoriza el ruido.
- $J(\theta)_{train} \ll J(\theta)_{test}$ (brecha grande).

Visualización del Trade-off

El objetivo del aprendizaje de máquina es encontrar el "punto dulce"que minimiza el error total.

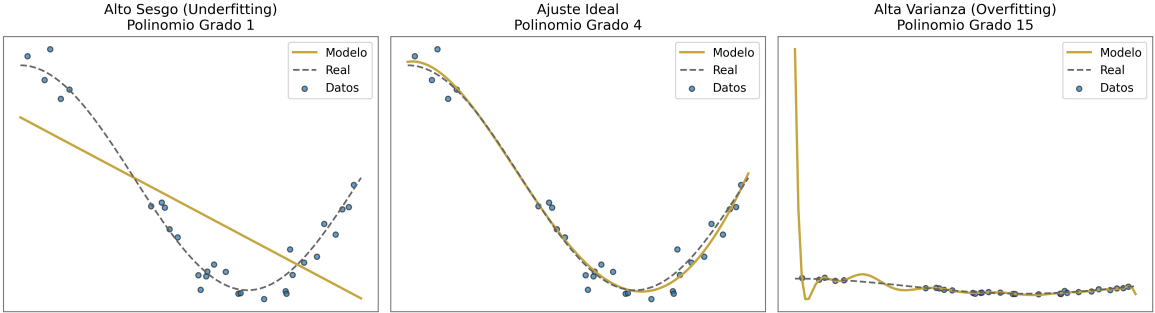

Introducción a la Regularización

Problema: Cuando tenemos alta varianza (overfitting), los parámetros θ tienden a tomar valores muy grandes para ajustarse a cada punto del entrenamiento.
Solución: Modificar la función de costo $J(\theta)$ añadiendo un término de penalización que **castigue** los valores grandes de θ.

Nueva Función de Costo Regularizada

$$J(\theta)_{reg} = J(\theta)_{original} + \lambda \cdot \mathcal{P}(\theta)$$

Donde $\lambda > 0$ es el **hiperparámetro de regularización** que controla qué tanto simplificamos el modelo.

Regresión Ridge (Regularización L2)

Ridge penaliza la suma de los **cuadrados** de los coeficientes. Esto encoge los parámetros asintóticamente hacia cero.

Función de Costo Ridge

$$J(\theta) = \frac{1}{2m} \sum_{i=1}^{m} (h_\theta(x^{(i)}) - y^{(i)})^2 + \lambda \sum_{j=1}^{n} \theta_j^2$$

*Nota: Convencionalmente no se penaliza el intercepto θ_0.

Características:

- Reduce la magnitud de todos los θ.
- Funciona bien con multicolinealidad.
- **No** hace selección de variables (todos los $\theta_j \neq 0$).

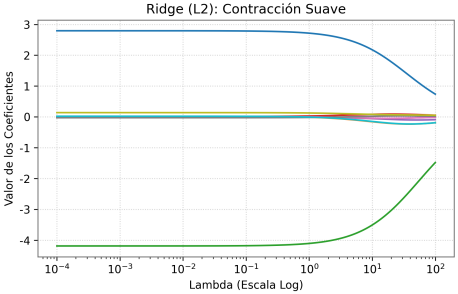

Regresión Lasso (Regularización L1)

Lasso penaliza la suma de los **valores absolutos** de los coeficientes. Esto fuerza a que algunos parámetros sean **exactamente cero**.

Función de Costo Lasso

$$J(\theta) = \frac{1}{2m} \sum_{i=1}^{m} (h_\theta(x^{(i)}) - y^{(i)})^2 + \lambda \sum_{j=1}^{n} |\theta_j|$$

Características:

- Realiza **Selección de Características** automática.
- Genera modelos "dispersos"(sparse).
- Ideal cuando sospechamos que pocas variables son relevantes.

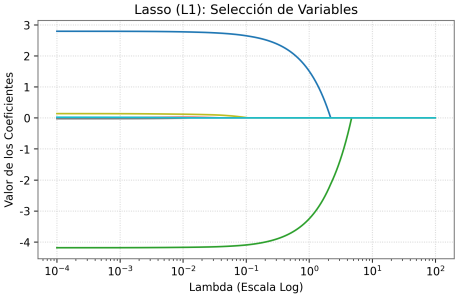

Método de Retención (Holdout Validation)

Es la estrategia más simple: dividir los datos en dos conjuntos excluyentes.

- **Entrenamiento (70-80 %):** Para ajustar los parámetros θ.
- **Prueba (20-30 %):** Para estimar el error de generalización.

Desventajas:

- "Desperdiciamos"datos de prueba.
- La estimación del error depende mucho de qué datos cayeron en el split (Alta varianza en la evaluación).

Validación Cruzada (K-Fold Cross-Validation)

El estándar de oro para conjuntos de datos medianos.

Algoritmo:

1. Dividir datos aleatoriamente en K pliegues (folds).
2. Para $k = 1$ hasta K:
   - Entrenar con $K - 1$ pliegues.
   - Validar con el pliegue restante.
3. Promediar los K errores resultantes.

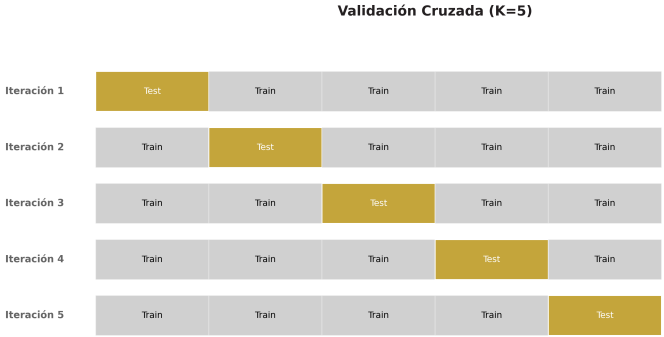

Bootstrapping

Técnica basada en el remuestreo **con reemplazo**.

Funcionamiento:

- Generar B datasets del mismo tamaño que el original tomando muestras con reemplazo.
- Entrenar B modelos y evaluar.

Uso Principal:

- Cuando tenemos muy pocos datos.
- Para estimar intervalos de confianza de los parámetros θ.

Dato

En promedio, cada muestra bootstrap contiene solo el $\approx 63{,}2\,\%$ de los datos únicos originales.

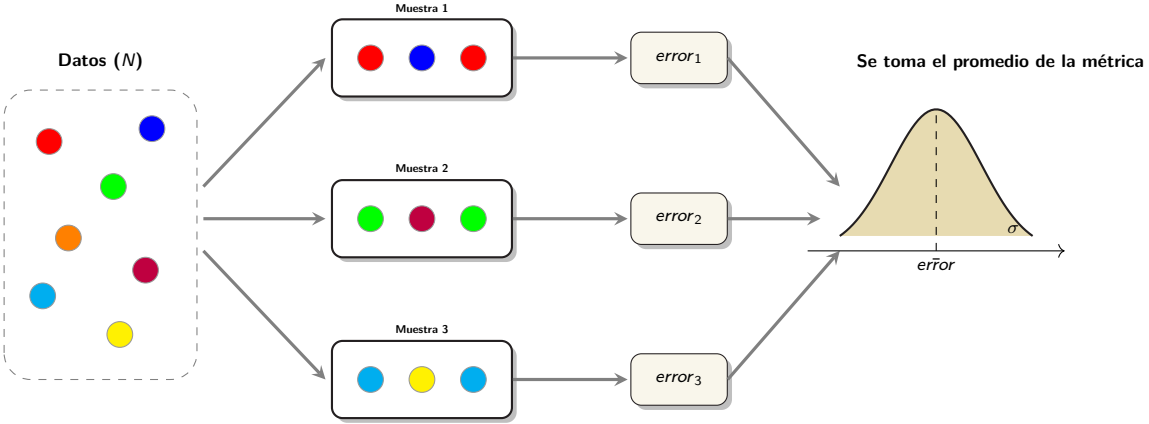
Datos (N)
Muestra 1
Muestra 2
Muestra 3
$error_1$
$error_2$
$error_3$
Se toma el promedio de la métrica
σ
$\bar{error}$