Técnicas de Limpieza, Imputación y Transformación de Datos

Diagnóstico Estadístico, Matemáticas y Algoritmos

Presentado por:
Rubén Manrique

Universidad de los Andes
Departamento de Ingeniería de Sistemas y Computación

Curso: ISIS-2611 Aprendizaje de Máquina
Profesor: Rubén Manrique

9 de febrero de 2026

El Costo del Ruido en Modelos Predictivos

Principio Fundamental: GIGO

"Garbage In, Garbage Out" $\rightarrow$ Un modelo entrenado con datos ruidosos o sesgados tendrá una capacidad de generalización pobre ($E_{out} >> E_{in}$).

Distinción Crítica:

- **Data Cleaning:** Corregir errores, imputar faltantes y suavizar ruido. El objetivo es *restaurar* la verdad del dato.
- **Feature Engineering:** Crear nuevas variables para mejorar el rendimiento.

Ejemplo: Un outlier no tratado en una Regresión Lineal "hala"la pendiente (β), introduciendo sesgo sistémico.

Descomposición del Error: Sea el error esperado de predicción:

$$Err(x) = \text{Sesgo}^2 + \text{Varianza} + \sigma_\epsilon^2$$

Consecuencias de una mala limpieza:

1. **Imputación por Media:** Reduce artificialmente la varianza ($\downarrow \sigma^2$), causando *Overfitting*.
2. **Eliminación de Filas (MCAR):** Reduce el tamaño muestral N, aumentando el error estándar de los coeficientes:

$$SE(\hat{\beta}) = \frac{\sigma}{\sqrt{\sum (x_i - \bar{x})^2}}$$

Conclusión: La limpieza no es estética, es una pre-condición estadística.

El Dilema Sesgo-Varianza (Bias-Variance Tradeoff)

El objetivo de la limpieza es minimizar el Error Total sin sacrificar la capacidad de generalización.

1. Sesgo (Bias) → Underfitting

Error debido a suposiciones erróneas o simplistas en el algoritmo de aprendizaje.

- **Causa:** El modelo no captura la complejidad de los datos (ej. usar regresión lineal para datos curvos).
- **Matemáticamente:** La diferencia entre la predicción promedio del modelo y el valor real.

$$\text{Bias}[\hat{f}(x)] = E[\hat{f}(x)] - f(x)$$

2. Varianza → Overfitting

Error debido a la sensibilidad excesiva a pequeñas fluctuaciones (ruido) en el set de entrenamiento.

- **Causa:** El modelo memoriza el ruido y los *outliers* en lugar de aprender el patrón.
- **Matemáticamente:** Cuánto varía la predicción para un punto dado si cambiamos el set de entrenamiento.

$$\text{Var}[\hat{f}(x)] = E[(\hat{f}(x) - E[\hat{f}(x)])^2]$$

Descomposición del Error Cuadrático Medio (MSE)

Para un punto x, el error esperado se descompone en:

$$E[(y - \hat{f}(x))^2] = \underbrace{(\text{Bias}[\hat{f}(x)])^2}_{\text{Error Sistemático}} + \underbrace{\text{Var}[\hat{f}(x)]}_{\text{Sensibilidad al Ruido}} + \underbrace{\sigma^2}_{\text{Error Irreducible}}$$

Visualización del Concepto

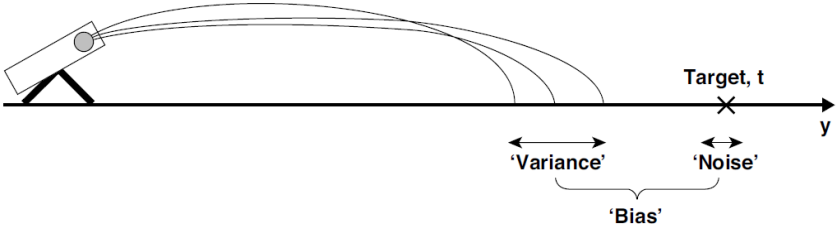

Figura: Descomposición Sesgo-Varianza (Bias-Variance Decomposition). Tomado de Introduction to Data Mining, Pang-Ning Tan, Michael Steinbach, Vipin Kumar

3. Diagnóstico de Mecanismos de Pérdida (Teoría)

Sea D el dataset completo, D_{obs} la parte observada y D_{miss} la parte faltante. Sea M una matriz binaria donde $M_{ij} = 1$ si falta el dato y 0 si está presente.

1. Missing Completely at Random (MCAR)

La probabilidad de ausencia es totalmente independiente de los datos.

$$P(M|D) = P(M)$$

Implicación: Es ruido aleatorio. Eliminar filas no introduce sesgo, solo reduce potencia estadística.

2. Missing at Random (MAR)

La ausencia depende de variables **observadas**, no del valor faltante en sí.

$$P(M|D) = P(M|D_{obs})$$

Implicación: Se puede corregir usando la información de las otras columnas (Ej: Imputación MICE).

3. Missing Not at Random (MNAR) - *El caso peligroso*

La ausencia depende del **valor faltante** desconocido.

$$P(M|D) = P(M|D_{obs}, D_{miss})$$

Implicación: El mecanismo de pérdida es informativo. **No se puede ignorar ni imputar simplemente.**

3.1. Ejemplos Prácticos: Diferenciando los Mecanismos

Imagina un dataset de **Encuestas de Salud** con variables: *Edad, Género, Peso*.

MCAR
(Aleatorio)

Caso: Se perdió una caja de formularios en el correo aleatoriamente.

Diagnóstico: La distribución de edades de los formularios perdidos es idéntica a la de los presentes.

Solución: Eliminar filas o Media.

MAR
(Condicional)

Caso: Las *Mujeres* (Género=F, observado) tienen más probabilidad de dejar el campo *Peso* vacío.

Diagnóstico: La falta de datos en 'Peso' correlaciona con la variable 'Género'.

Solución: MICE o Regresión (Usar Género para predecir Peso).

MNAR
(Sesgo Sistémico)

Caso: Las personas con *Sobrepeso* (valor no observado) prefieren no reportar su peso.

Diagnóstico: Imposible de confirmar con los datos (requiere conocimiento del dominio).

Solución: Modelar el mecanismo de pérdida explícitamente.

3.2. Diagnóstico Visual y Estadístico (Python)

Antes de imputar, debemos visualizar la **Matriz de Nulidad**.

Herramienta: Librería `missingno`

- `msno.matrix(df)`: Visualiza la densidad de datos.
- `msno.heatmap(df)`: Correlación de nulidad (¿Si falta A, falta B?).

Test de Little (MCAR Test):

$$H_0 : \text{Los datos son MCAR}$$

$$H_1 : \text{Los datos NO son MCAR (son MAR o MNAR)}$$

Si p-value $< 0{,}05 \rightarrow$ Rechazamos MCAR. Debemos usar técnicas robustas (MICE).

Matriz de Nulidad (Ejemplo)

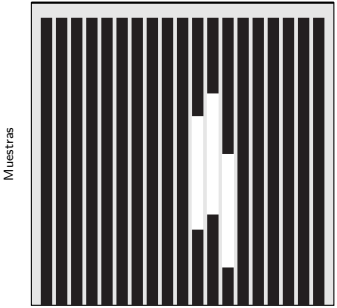

Gráfico conceptual similar a msno.matrix()

4. Técnicas Univariadas: Definiciones y Supuestos

Estas técnicas ignoran las correlaciones entre variables. Asumen que la variable X_j es independiente de X_{-j}.

Imputación por Media ($\bar{x}$)

Para variables continuas con distribución Normal (Simétrica).

$$\hat{x}_i = \frac{1}{n_{obs}} \sum_{k \in obs} x_k$$

Supuesto: Datos MCAR.

Imputación por Mediana (x_{med})

Robustez ante *outliers* o distribuciones sesgadas (*skewed*).

$$\hat{x}_i = \text{percentil}_{50}(X_{obs})$$

Imputación por Moda (Mo)

Para variables categóricas o discretas con baja cardinalidad.

$$\hat{x}_i = \text{argmax}_v P(X = v)$$

¡Regla de Oro!

Solo utilizar estas técnicas si:

1. El porcentaje de faltantes es bajo ($< 5\,\%$).
2. El mecanismo es puramente aleatorio (MCAR).

4.1. ¿Por qué fallan? El Colapso de la Varianza

Al reemplazar valores faltantes con una constante c (la media), estamos inyectando datos con **cero varianza** respecto al centro de la distribución.

Consecuencia 1: Subestimación de la Varianza Real

- Sea S^2_{orig} la varianza original y S^2_{imp} la varianza post-imputación.
- Al imputar m valores con la media $\bar{x}$:

$$S^2_{imp} \approx \left(\frac{n_{obs}}{n_{total}}\right) S^2_{orig} < S^2_{orig}$$

Consecuencia 2: Sesgo en la Covarianza

- La correlación entre la variable imputada X y cualquier otra variable Y se debilita (tiende a cero), porque los valores imputados no varían con Y.

$$|Corr(X_{imp}, Y)| < |Corr(X_{orig}, Y)|$$

4.2. Visualización del Fallo: .El Pico Artificial"

Ejemplo: Variable con distribución Normal $N(0,1)$ y 30 % de datos faltantes imputados por la media.

Efecto en la PDF:

- Se genera una distribución **Leptocúrtica** (Pico excesivo en el centro).
- Los intervalos de confianza se vuelven irrealmente estrechos.
- El modelo se "sobre-confía.en el valor promedio.

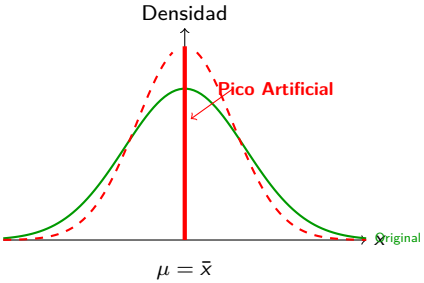

Figura: Distorsión de la función de densidad de probabilidad (PDF).

5. KNN Imputation: El Enfoque Local

Intuición: "Dime con quién andas..."

A diferencia de la media (que asume que todos los datos son iguales), KNN asume que **muestras similares en el espacio de características tendrán valores similares en la variable faltante.**

El Algoritmo Paso a Paso:

1. **Selección:** Identificar la fila u que tiene un valor faltante en la variable j.
2. **Búsqueda:** Calcular la distancia entre u y todos los demás puntos v del dataset (usando las variables observadas).
3. **Vecindad:** Seleccionar los k puntos más cercanos (N_k).
4. **Imputación:** Calcular el valor faltante como un promedio (simple o ponderado) de los valores de los vecinos.

Requisito Crítico: Todas las variables deben estar ESCALADAS (Normalizadas) antes de usar KNN.

5.1. Matemática de la Imputación KNN

Sea x_u la muestra con dato faltante y x_v un vecino candidato.

1. Métrica de Distancia (Euclidiana) Calculada solo sobre las dimensiones D donde ambos tienen datos observados:

$$d(u, v) = \sqrt{\sum_{d \in D_{obs}} (x_{u,d} - x_{v,d})^2}$$

**Nota: Sensible a escalas no normalizadas.*

2. Estimación Ponderada Es preferible ponderar por el inverso de la distancia ($w_v = \frac{1}{d(u,v)}$) para dar más importancia a los vecinos muy cercanos.

$$\hat{x}_{u,j} = \frac{\sum_{v \in N_k} w_v \cdot x_{v,j}}{\sum_{v \in N_k} w_v}$$

Trade-off del Hiperparámetro k:

- **k pequeño (ej. $k = 1$):** Alta varianza, sensible a ruido/outliers.
- **k grande:** Alto sesgo, tiende a convertirse en la media global.
- **Valor típico:** $\sqrt{N}$ o validación cruzada (ej. $k = 5$).

5.2. Visualización: La Vecindad Local

Interpretación:

- El punto **rojo** tiene un dato faltante.
- Buscamos en el espacio 2D (Features A y B).
- Los 3 vecinos más cercanos (**azules**) definen el valor.
- Los puntos lejanos (grises) son ignorados (preservando la estructura local).

Desventaja: Costo Computacional $O(N^2)$. Lento en Big Data.

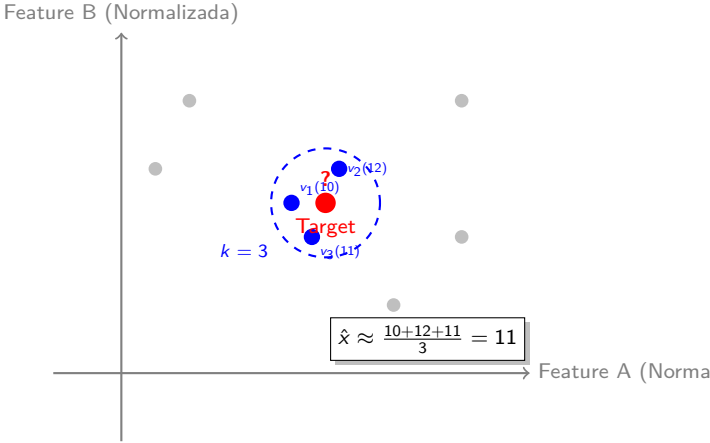

6. MICE: El Estándar de Oro (Multivariado)

Cambio de Paradigma

En lugar de tratar los datos faltantes como un problema de relleno", MICE los trata como un **problema de predicción**.

- Cada variable con faltantes se convierte, por turnos, en la **Variable Objetivo (Y)**.
- Las demás variables actúan como **Predictores (X)**.

¿Por qué es "Global¿ A diferencia de KNN (que mira vecinos locales), MICE modela la estructura de correlación global de todo el dataset.

Supuesto: Missing At Random (MAR). Asume que la información para imputar X_j reside en las otras columnas X_{-j}.

Ventaja Estadística

Al añadir un componente estocástico (ruido) en la regresión, MICE preserva no solo la media, sino también la **varianza y la covarianza** original de los datos.

6.1. El Algoritmo: Ecuaciones Encadenadas

El proceso se basa en el muestreo de Gibbs (*Gibbs Sampling*). Iteramos sobre las variables $j = 1, \dots, p$ para actualizar sus valores imputados.

Paso 0: Inicialización $\rightarrow$ Rellenar todos los nulos con la media (temporal).

Paso 1: Ciclo Iterativo (Repetir k veces) Para cada variable X_j en la iteración t:

1. Definir Feature Matrix actual: $X_{-j}^{(t)} = \{X_1^{(t)}, \dots, X_{j-1}^{(t)}, X_{j+1}^{(t-1)}, \dots\}$
2. Entrenar modelo de regresión (Lineal, Bayesiano, etc.):
$$X_j^{obs} \sim f(X_{-j}^{obs}, \theta_j)$$
3. Predecir (Imputar) los valores faltantes:
$$X_j^{miss(t)} = \hat{f}(X_{-j}^{miss}, \hat{\theta}_j) + \epsilon, \quad \text{donde } \epsilon \sim N(0, \sigma^2)$$

**Nota: El término ϵ es crucial para restaurar la variabilidad natural y evitar correlaciones perfectas (deterministas).*

6.2. Visualización del Ciclo y Convergencia

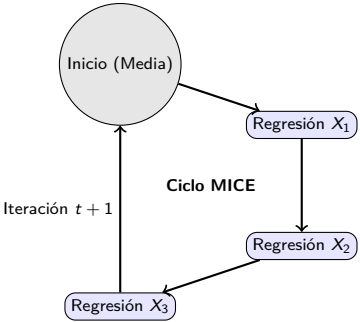

Criterio de Parada (Convergencia):

- Se repite el ciclo hasta que la diferencia entre las imputaciones de t y $t-1$ sea despreciable.

$$\sum |X^{(t)} - X^{(t-1)}| < \delta$$

- Usualmente converge rápido (10-20 iteraciones).

En Python (sklearn):

```
IterativeImputer(estimator=BayesianRidge())
```

¿Por qué inicializar con valores aleatorios?

El Problema del "Huevo y la Gallina"

Para imputar la variable X_1, necesitamos usar X_2 como predictor. Pero si X_2 también tiene faltantes, la regresión matemática ($Y = X\beta$) es imposible de calcular.

El Proceso de Refinamiento:

1. **Estado 0 (Inicial):** Rellenamos los huecos con valores al azar (Placeholders).
2. **Iteración 1:** Los modelos son ruidosos, pero aprenden la estructura global básica.
3. **Iteración N (Convergencia):** Gracias a la propiedad de las *Cadenas de Markov*, el punto de partida se olvida y los datos convergen a su distribución real.

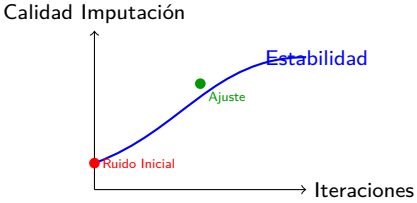

.El valor inicial no importa, importa la convergencia."

8. Detección de Outliers: Paramétrico vs. Robusto

Un *Outlier* es una observación que se desvía tanto de las otras observaciones que levanta sospechas de haber sido generada por un mecanismo diferente.

1. Método Z-Score (Paramétrico)

Asume que los datos siguen una distribución $X \sim \mathcal{N}(\mu, \sigma^2)$.

$$Z_i = \frac{x_i - \mu}{\sigma}$$

Criterio: Si $|Z_i| > 3$, es un outlier.
Falla si la distribución es asimétrica.

2. Rango Intercuartílico - IQR (Robusto)

Basado en el orden (Tukey). No depende de la media.

- $IQR = Q_3 - Q_1$
- $LI = Q_1 - 1{,}5 \times IQR$
- $LS = Q_3 + 1{,}5 \times IQR$

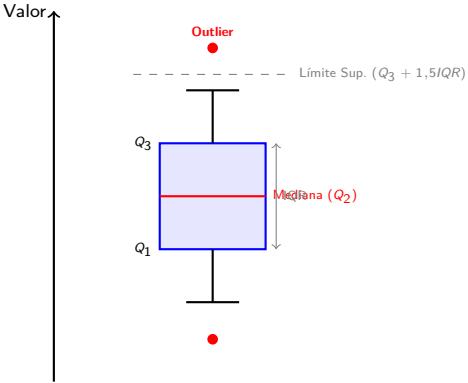

9. Limpieza de Datos Categóricos e Inconsistencias

El ruido en texto (typos) genera una explosión de cardinalidad (Ej: "Bogotá", "bogota", "Bogota D.C."son interpretados como 3 categorías distintas).

Técnica: Fuzzy Matching (Coincidencia Difusa)

Utiliza métricas de distancia entre cadenas de caracteres para unificar categorías similares.

Definición Matemática: Distancia de Levenshtein ($lev_{a,b}$) Es el número mínimo de ediciones (inserción, eliminación o sustitución) para transformar la cadena a en b.

$$\text{lev}_{a,b}(i,j) = \begin{cases} \text{máx}(i,j) & \text{si } \text{mín}(i,j) = 0, \\ \text{mín} \begin{cases} \text{lev}_{a,b}(i-1,j) + 1 \\ \text{lev}_{a,b}(i,j-1) + 1 \\ \text{lev}_{a,b}(i-1,j-1) + 1_{(a_i \neq b_j)} \end{cases} & \text{en otro caso.} \end{cases}$$

Ejemplo Práctico:

Input (Sucio)	Target	Distancia	Acción	Resultado
Üniversdad"	Üniversidad"	1	Imputar	Üniversidad"
Ünierrsidad"	Üniversidad"	2	Imputar	Üniversidad"
Üniverso"	Üniversidad"	5	Ignorar	(Nueva Categoría)

Herramienta Python: `fuzzywuzzy` o `rapidfuzz`

10. Transformación de Datos: De la Calidad a la Usabilidad

Definición Formal

Proceso determinista de mapeo $T : \mathcal{X} \to \mathcal{X}'$ donde se altera la representación de los datos (no su veracidad) para facilitar el aprendizaje del modelo $\hat{f}$.

¿Por qué transformar datos limpios?

1. **Compatibilidad Algebraica:** Los modelos (Regresión, Redes Neuronales) son operaciones matriciales. No entienden strings Alto/Bajo.
2. **Convergencia:** El Descenso del Gradiente converge más rápido si las curvas de nivel son circulares (datos escalados) y no elípticas alargadas.
3. **Distancias:** Evitar que variables con magnitudes grandes (Salario) dominen a las pequeñas (Edad).

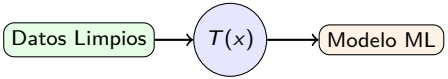

"Limpieza es corregir errores. Transformación es optimizar la geometría del dato."

11. Escalado de Características (Feature Scaling)

Crítico para algoritmos basados en distancias (KNN, K-Means, SVM) y optimización por gradiente.

1. Estandarización (Z-Score)

Centra los datos en 0 con desviación estándar 1.

$$x_i' = \frac{x_i - \mu}{\sigma}$$

Uso: SVM, Regresión Logística, cuando se asume Gaussianidad. Preserva outliers (en magnitud relativa).

2. Normalización (Min-Max)

Comprime los datos en un rango fijo $[0, 1]$.

$$x_i' = \frac{x_i - x_{min}}{x_{max} - x_{min}}$$

Uso: Redes Neuronales, procesamiento de Imágenes. Sensible a outliers.

¡Advertencia de Data Leakage!

Los parámetros de escalado (μ, σ, min, max) se calculan **SOLO** con el `Train Set`. Luego se aplican al `Test Set`.
`scaler.fit(X_train)` $\rightarrow$ `scaler.transform(X_train)` y `scaler.transform(X_test)`

12. Codificación de Variables Categóricas

Debemos transformar texto a tensores numéricos sin introducir relaciones espurias.

A. Ordinal Encoding

- Para datos con jerarquía intrínseca.
- *Ejemplo:* [Bajo, Medio, Alto] $\rightarrow [0, 1, 2]$.
- Preserva la relación de orden ($0 < 1 < 2$).

B. One-Hot Encoding (OHE)

- Para datos Nominales (Sin orden).
- Crea K columnas binarias (o $K - 1$ para evitar multicolinealidad perfecta).
- *Ejemplo:* [Perro, Gato] $\rightarrow$

Is_Perro	Is_Gato
1	0
0	1

Riesgos Matemáticos:

1. **Falso Orden:** Si aplicas Ordinal Encoding a Çiudades"(Bogotá=1, Cali=2, Medellín=3), el modelo creerá que *Medellin* > *Bogota* y que la media es Cali. **¡Error Grave!**
2. **Maldición de la Dimensionalidad:** OHE en variables con alta cardinalidad (ej. Código Postal) genera matrices dispersas (*Sparse Matrices*) enormes, haciendo el entrenamiento ineficiente.

13. Feature Engineering: Expansión del Espacio

Crear nuevas variables a partir de las existentes para capturar relaciones no lineales o conocimiento del dominio.

1. Características Polinómicas y de Interacción

Si un modelo lineal $y = w_1 x_1 + w_2 x_2$ no ajusta bien, expandimos la base:

$$\phi(x) = [1, x_1, x_2, x_1^2, x_1 x_2, x_2^2]$$

Esto permite a un modelo lineal aprender fronteras de decisión curvas (elipses, parábolas).

2. Transformaciones de Distribución (Log-Transform)

Para variables con asimetría positiva (*Right Skewed*), como ingresos o precios.

$$x' = \ln(1 + x)$$

Efecto: .^plana"los valores extremos y acerca la distribución a una Normal, estabilizando la varianza del error.

Ejemplo de Dominio: En lugar de usar `Precio` y `Area` por separado, crear `Precio_m2 = Precio / Area`. Esta nueva variable suele tener mayor poder predictivo.