Regresión Lineal: Introducción y Motivación

Fundamentos, Matemáticas y Algoritmos

Presentado por:
Rubén Manrique

Universidad de los Andes
Departamento de Ingeniería de Sistemas y Computación

Curso: Aprendizaje de Máquina
Semestre: 2026-10

9 de febrero de 2026

Agenda

1. Introducción y Motivación
2. El Modelo Matemático
3. Función de Pérdida (Loss Function)
4. Gradiente Descendente
5. Supuestos del Modelo
6. Ejercicio Práctico
7. Introducción a la Evaluación
8. Métricas de Error Absoluto y Cuadrático
9. Coeficiente de Determinación (R^2)

¿Qué es la Regresión Lineal?

Definición Formal:

Es un algoritmo de **aprendizaje supervisado** que modela la relación entre una variable dependiente continua y y una o más variables independientes x.

Objetivo: Encontrar la función lineal que mejor se ajuste a los datos para predecir valores futuros.

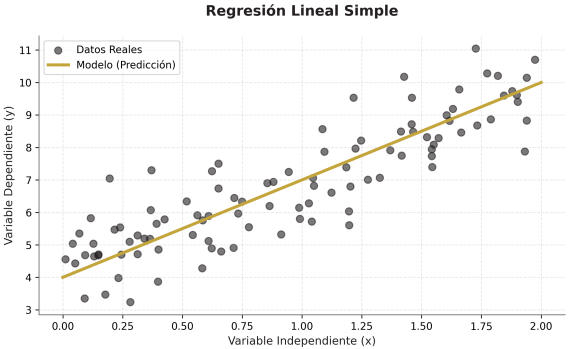

Figura: Fuente: Elaboración propia basada en Bishop, C. (2006).

Contexto: Regresión vs. Clasificación

Regresión (Nuestro Foco)

Predice un **valor numérico continuo** (infinito dentro de un rango).

- Ej: Precio de una acción, temperatura, ventas trimestrales.

Clasificación

Predice una **etiqueta de clase discreta** (categoría).

- Ej: Correo Spam/No Spam, Tumor Benigno/Maligno.

Ejemplo Práctico 1: Mercado Inmobiliario

Problema: ¿Cómo tasar una vivienda automáticamente?

Consideramos que el precio aumenta linealmente con el tamaño.

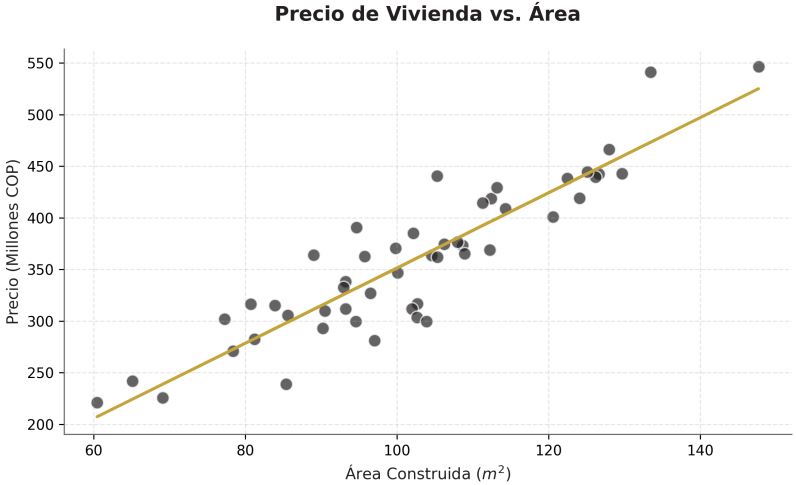

Ejemplo Práctico 2: Rendimiento Académico

Podemos modelar el éxito estudiantil como función del esfuerzo.

- **Variable x (Input):** Horas de estudio semanal.
- **Variable y (Output):** Calificación final (0.0 - 5.0).

Intuición: A más horas de estudio, mayor nota esperada (correlación positiva).

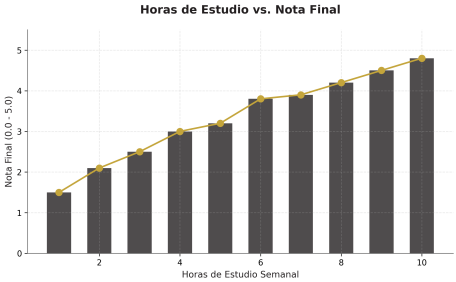

Figura: Fuente: Dataset "Student Performance", UCI Repository.

"Todos los modelos son erróneos, pero algunos son útiles."

— George E. P. Box

Un poco de Historia: Francis Galton (1885)

Regresión a la Media:

- Galton estudió la altura de padres e hijos.
- Observó que los hijos de padres muy altos tendían a ser más bajos que sus padres, acercándose al promedio poblacional.
- A este fenómeno lo llamó regresión.

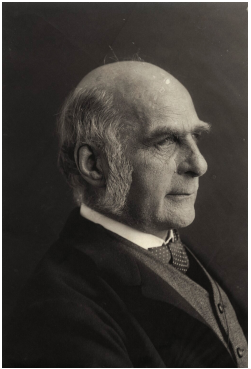

Figura: Fuente: National Portrait Gallery, Londres.

¿Por qué estudiar Regresión Lineal hoy?

A pesar de existir algoritmos complejos (Deep Learning), la regresión lineal sigue vigente por:

1. **Simplicidad e Interpretabilidad:**
   - Sabemos exactamente cómo afecta cada variable al resultado (peso β).
2. **Eficiencia Computacional:**
   - Entrena en milisegundos incluso con grandes volúmenes de datos.
3. **Base Fundamental:**
   - Es el bloque constructivo de las redes neuronales (una neurona es básicamente una regresión lineal con una función de activación).

Flujo de Trabajo en ML

Pasos para construir el modelo:

- **Recolección:** Obtener pares (x, y).
- **Entrenamiento:** Ajustar los parámetros para minimizar el error.
- **Evaluación:** Probar con datos nuevos.

La Ecuación de Regresión Lineal Simple

El modelo asume que la relación entre la variable de entrada x y la salida y es aproximadamente lineal:

$$y = \beta_0 + \beta_1 x + \epsilon \tag{1}$$

Componentes del Modelo:

- y: Variable dependiente, respuesta o *target*.
- x: Variable independiente, predictor o *feature*.
- β_0: Intercepto (o *bias*). Es el valor de y cuando $x = 0$.
- β_1: Pendiente (o *weight*). Indica cuánto cambia y por cada unidad que aumenta x.
- ϵ: Error aleatorio o ruido (aquello que el modelo no puede explicar).

Interpretación Geométrica

Geométricamente, estamos intentando ajustar una **línea recta** a través de una nube de puntos de tal manera que las distancias (residuos) sean mínimas.

Hipótesis (h_θ)

En Machine Learning, solemos denotar la predicción como:

$$\hat{y} = h_\theta(x) = \theta_0 + \theta_1 x$$

Donde θ representa los parámetros que el algoritmo debe aprender.

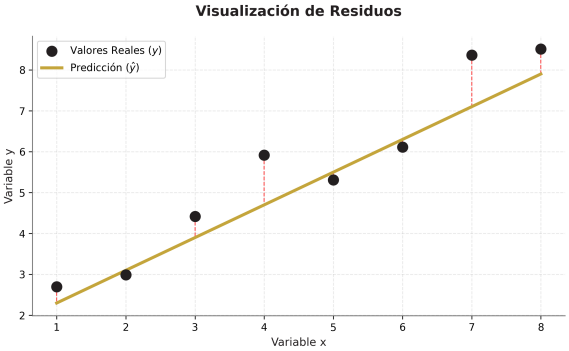

Figura: Fuente: Elaboración propia. Generar con grafico_residuos.png

¿Qué es el Error (ϵ)?

El error o residuo de una observación individual i se define como la diferencia entre el valor real y la predicción del modelo:

$$e^{(i)} = y^{(i)} - \hat{y}^{(i)} \tag{2}$$

- Si $e > 0$: El modelo subestima el valor real.
- Si $e < 0$: El modelo sobreestima el valor real.
- **Meta:** Queremos que la suma de todos estos errores sea la menor posible.

¿Cómo medimos qué tan bueno es el modelo?

Para saber si una línea es mejor que otra, necesitamos una métrica cuantitativa. Esta es la **Función de Pérdida** (o Función de Costo).

¿Por qué no sumar simplemente los errores ($e^{(i)}$)?

- Los errores positivos y negativos se cancelarían entre sí.
- Un modelo con errores enormes podría parecer "perfecto"si su suma es cero.

Solución: Elevar los errores al cuadrado.

- Elimina el signo negativo.
- **Penaliza** más fuerte a los errores grandes (los *outliers*).

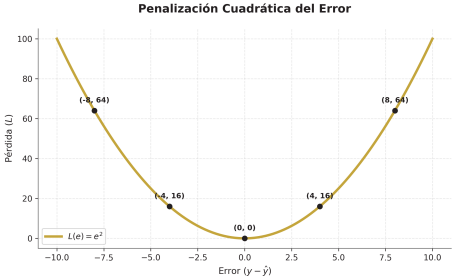

Figura: Fuente: Elaboración propia.

Error Cuadrático Medio (MSE)

La función de costo más común para la regresión lineal es el **Mean Squared Error (MSE)**, denotada comúnmente como $J(\theta)$:

$$J(\theta_0, \theta_1) = \frac{1}{2m} \sum_{i=1}^{m} \left(h_\theta(x^{(i)}) - y^{(i)} \right)^2 \tag{3}$$

Desglose de la fórmula:

- m: Número total de muestras en el dataset.
- $1/m$: Promedio del error.
- $(\ldots)^2$: El cuadrado de la diferencia entre la predicción y el valor real.
- El factor $1/2$ se añade por conveniencia matemática para simplificar la derivada durante la optimización.

La Superficie de Costo

$J(\theta)$ define una superficie en un espacio 3D (cuando tenemos dos parámetros θ_0 y θ_1).

- Es una función **convexa** (forma de tazón).
- **Propiedad Crítica:** Tiene un único mínimo global. No hay mínimos locales que atrapen al algoritmo.
- Nuestro objetivo es rodar hasta el punto más bajo de este tazón.

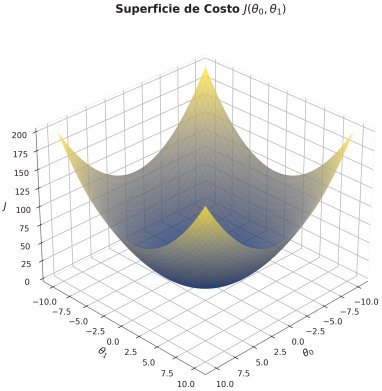

Figura: Fuente: Elaboración propia.

La Superficie de Costo

$J(\theta)$ define una superficie en un espacio 3D (cuando tenemos dos parámetros θ_0 y θ_1).

- Es una función **convexa** (forma de tazón).
- **Propiedad Crítica:** Tiene un único mínimo global. No hay mínimos locales que atrapen al algoritmo.
- Nuestro objetivo es rodar hasta el punto más bajo de este tazón.

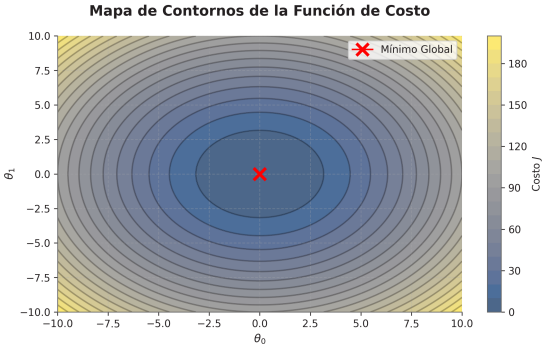

Figura: Fuente: Elaboración propia.

Ecuaciones Normales: Mínimos Cuadrados Ordinarios (OLS)

La solución analítica busca el valor de θ que minimiza la suma de errores al cuadrado sin necesidad de iteraciones.

La Ecuación Normal

$$\hat{\theta} = (\mathbf{X}^T\mathbf{X})^{-1}\mathbf{X}^T\mathbf{Y}$$

Explicación del Método:

- $\mathbf{X}^T\mathbf{X}$: Representa la relación entre las variables de entrada (matriz de covarianza).
- $(\dots)^{-1}$: Despeja los parámetros eliminando la dependencia entre variables.
- $\mathbf{X}^T\mathbf{Y}$: Proyecta la relación de las entradas con la variable objetivo.

Es la solución óptima si la matriz es invertible y el dataset cabe en memoria.

Ejemplo Práctico de Cálculo Analítico

Supongamos dos puntos: $(x = 1, y = 2)$ y $(x = 2, y = 2{,}5)$. Buscamos $\hat{y} = \theta_0 + \theta_1 x$.

1. Definir Matrices:

$$X = \begin{bmatrix} 1 & 1 \\ 1 & 2 \end{bmatrix}, Y = \begin{bmatrix} 2 \\ 2{,}5 \end{bmatrix}$$

2. Calcular $X^T X$:

$$\begin{bmatrix} 1 & 1 \\ 1 & 2 \end{bmatrix} \begin{bmatrix} 1 & 1 \\ 1 & 2 \end{bmatrix} = \begin{bmatrix} 2 & 3 \\ 3 & 5 \end{bmatrix}$$

3. Inversa $(X^T X)^{-1}$:

$$det = (2 \cdot 5) - (3 \cdot 3) = 1$$

$$(X^T X)^{-1} = \begin{bmatrix} 5 & -3 \\ -3 & 2 \end{bmatrix}$$

4. Multiplicar por $X^T Y$:

$$\hat{\theta} = \begin{bmatrix} 5 & -3 \\ -3 & 2 \end{bmatrix} \begin{bmatrix} 4{,}5 \\ 7 \end{bmatrix} = \begin{bmatrix} 1{,}5 \\ 0{,}5 \end{bmatrix}$$

Modelo: $\hat{y} = 1{,}5 + 0{,}5x$

Derivación de la Función de Pérdida

Para optimizar de forma iterativa, calculamos la derivada de la pérdida $J(\theta)$ respecto a cada parámetro θ_j.

Función de Pérdida (MSE)

$$J(\theta) = \frac{1}{2m} \sum_{i=1}^{m} (h_\theta(x^{(i)}) - y^{(i)})^2$$

Paso a paso de la Derivada:

1. Aplicamos la **regla de la cadena**: $\frac{d}{du} \frac{1}{2} u^2 = u \cdot \frac{du}{dx}$.
2. El exponente 2 baja y se cancela con el $1/2$.
3. Obtenemos el gradiente para el parámetro j:

$$\frac{\partial J}{\partial \theta_j} = \frac{1}{m} \sum_{i=1}^{m} \underbrace{(h_\theta(x^{(i)}) - y^{(i)})}_{\text{Error}} \cdot \underbrace{x_j^{(i)}}_{\text{Input}}$$

Algoritmo: Gradiente Descendente

El algoritmo busca el mínimo de la función de pérdida caminando en dirección opuesta al gradiente.

Pseudocódigo (Vectorizado)

Inicializar: θ (usualmente en ceros).
Repetir hasta convergencia:

1. Calcular predicciones: $\hat{Y} = X\theta$
2. Calcular vector de errores: $E = (\hat{Y} - Y)$
3. Calcular gradiente: $\nabla J = \frac{1}{m} X^T E$
4. Actualizar: $\theta := \theta - \alpha \cdot \nabla J$

Nota sobre la actualización: Multiplicar la matriz transpuesta X^T por el error E suma automáticamente la influencia de cada muestra, escalada por el valor de su característica correspondiente.

Implementación Práctica (Python)

A continuación, se muestra cómo se traduce la matemática a código ejecutable:

```python
import numpy as np

def gradient_descent(X, y, theta, alpha, iterations):
    m = len(y)
    cost_history = []

    for i in range(iterations):
        # 1. Prediccion
        prediction = np.dot(X, theta)
        # 2. Error
        error = prediction - y
        # 3. Gradiente (Vectorizado)
        gradient = (1/m) * np.dot(X.T, error)
        # 4. Actualizacion
        theta = theta - alpha * gradient

        # Guardar historial de costo para diagnostico
        cost = (1/(2*m)) * np.sum(np.square(error))
        cost_history.append(cost)

    return theta, cost_history
```

El rol de la Tasa de Aprendizaje (α)

La tasa de aprendizaje (α) es el hiperparámetro más crítico del Gradiente Descendente, pues determina el tamaño de los "pasos"hacia el mínimo.

- α **muy pequeño**: El algoritmo da pasos minúsculos. La convergencia es extremadamente lenta y costosa.
- α **ideal**: Convergencia eficiente y suave hacia el mínimo global.
- α **muy grande**: El algoritmo puede "saltar"sobre el mínimo, oscilar o incluso **diverger** (el error aumenta).

Figura: Comportamiento según el valor de α.

Supuesto 1: Linealidad

Definición: Existe una relación lineal entre la variable dependiente y las independientes.

- El cambio en Y debe ser proporcional al cambio en X.
- Si la relación es no lineal, el modelo tendrá un alto sesgo.

Diagnóstico: Gráfico de dispersión de los datos originales.

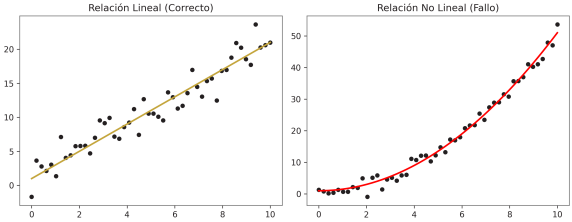

Figura: Fuente: Elaboración propia.

Supuesto 2: No Multicolinealidad

Definición: Las variables independientes no deben estar altamente correlacionadas entre sí.

- La multicolinealidad dificulta separar el efecto individual de cada predictor.
- Infla la varianza de los coeficientes estimados.

Diagnóstico: Matriz de correlación o factor VIF.

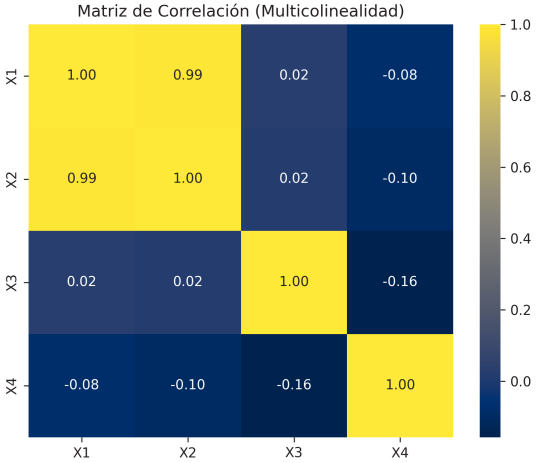

Figura: Fuente: Elaboración propia.

Supuesto 3: Normalidad de los Errores

Definición: Los residuos del modelo deben seguir una distribución normal con media cero.

- Es crucial para la validez de las pruebas t y F (inferencia estadística).
- Permite construir intervalos de confianza fiables.

Diagnóstico: Histograma de residuos o gráfico Q-Q.

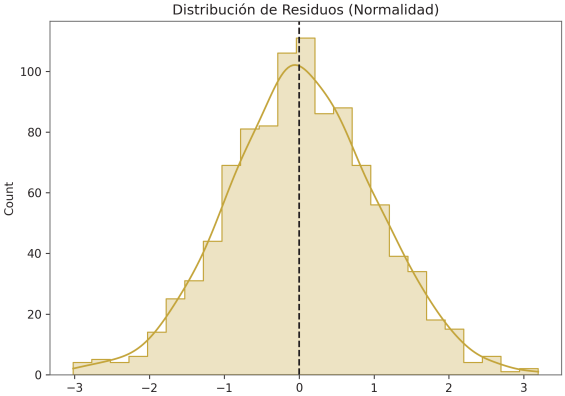

Figura: Fuente: Elaboración propia.

Supuesto 4: Homocedasticidad

Definición: La varianza de los errores es constante para todas las observaciones.

- Si la varianza cambia (Heterocedasticidad), el modelo pierde eficiencia.
- Común cuando el error crece proporcionalmente a X.

Diagnóstico: Gráfico de residuos vs. valores predichos.

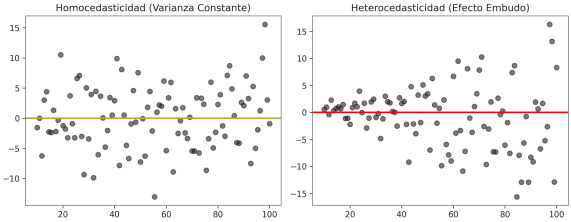

Figura: Fuente: Elaboración propia.

Escalamiento de Características

¿Es necesario escalar? **Sí.**

- Si $x_1 \in [0, 1]$ y $x_2 \in [0, 1000]$, la superficie de costo se vuelve elíptica y estrecha.
- El gradiente oscila y tarda más en converger.
- Al normalizar ($z = \frac{x-\mu}{\sigma}$), los contornos se vuelven circulares, permitiendo una ruta directa al mínimo.

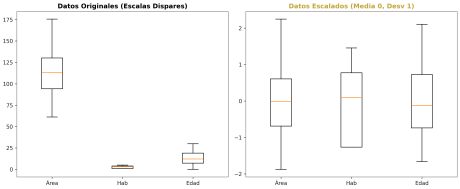

Dataset de Predicción Inmobiliaria

Usaremos 3 características para predecir el precio (y):

Muestra	Área (m^2)	Hab.	Edad	Precio (M)
1	120	3	5	350
2	85	2	15	240
...	...	...	...	...

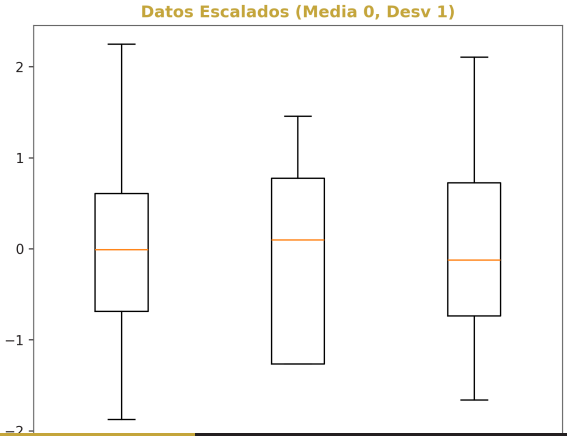

Implementación y Resultados

```
# Entrenamiento en Python
scaler = StandardScaler()
X_s = scaler.fit_transform(X)
model = LinearRegression()
model.fit(X_s, y)
```

Ecuación Resultante:

$$\hat{y} = 280{,}16 + 56{,}73 z_{area} + 21{,}54 z_{hab} - 20{,}72 z_{edad}$$

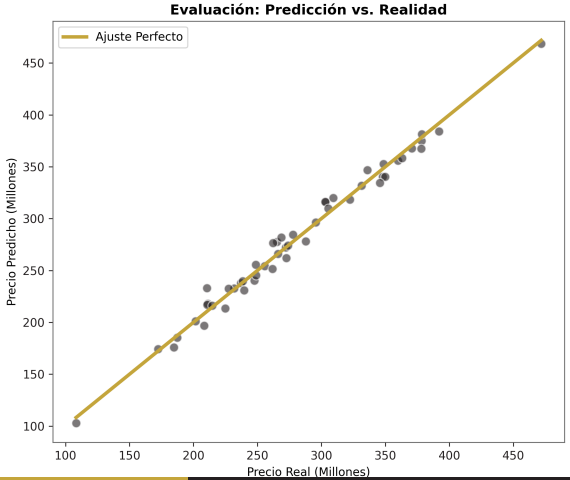

¿Por qué evaluar?

Entrenar un modelo es solo la mitad del trabajo. Necesitamos cuantificar su capacidad de generalización.

Objetivos de las métricas:

- Comparar diferentes algoritmos o configuraciones.
- Estimar el error en datos no vistos (test set).
- Comunicar resultados de forma objetiva al negocio.

Pregunta Clave

¿Un error de $10.000 USD es mucho o poco?
Depende de si predices el precio de un café o el de una casa.

MAE vs MSE vs RMSE

Métrica	Fórmula	Característica Principal
MAE	$\frac{1}{m}\sum_{i=1}^{m}\lvert y^{(i)} - \hat{y}^{(i)}\rvert$	Robusto a outliers (error lineal).
MSE	$\frac{1}{m}\sum_{i=1}^{m}(y^{(i)} - \hat{y}^{(i)})^2$	Penaliza errores grandes (cuadrático).
RMSE	$\sqrt{MSE}$	En las mismas unidades que y.

MAE (Mean Absolute Error)

Es el promedio de los errores absolutos. Es fácil de interpretar pero no diferencia entre un error pequeño y uno catastrófico.

RMSE (Root Mean Squared Error)

Es la métrica estándar. Si el RMSE es alto, significa que el modelo está cometiendo errores muy grandes en algunas muestras.

R^2: ¿Qué tanta varianza explicamos?

El R^2 compara nuestro modelo con un "modelo base"que siempre predice el promedio de y.

$$R^2 = 1 - \frac{SS_{res}}{SS_{tot}} = 1 - \frac{\sum(y^{(i)} - \hat{y}^{(i)})^2}{\sum(y^{(i)} - \bar{y})^2} \tag{4}$$

- $R^2 = 1$: Ajuste perfecto.
- $R^2 = 0$: El modelo es tan bueno como predecir la media.
- $R^2 < 0$: El modelo es peor que predecir la media (posible error en el modelo).

Cuidado con el R^2

Aumentar el número de variables siempre aumentará (o mantendrá) el R^2, incluso si las variables son ruido. Para esto usamos el R^2 **ajustado**.

¿Qué significa un $R^2 = 0{,}85$?: Significa que el 85 % de las razones por las que los precios de los apartamentos suben o bajan son explicadas por las variables que metiste en tu modelo (como el área o la ubicación). El otro 15 % es puro ruido o factores desconocidos.

R^2 Ajustado

El R^2 **Ajustado** soluciona el problema de la inflación artificial al incluir una penalización por cada variable adicional en el modelo.

Fórmula del R^2 Ajustado

$$R^2_{adj} = 1 - \left[\frac{(1 - R^2)(n - 1)}{n - p - 1} \right]$$

Donde:

- n: Tamaño de la muestra (número total de observaciones).
- p: Número de variables independientes (predictores) en el modelo.
- R^2: Coeficiente de determinación estándar.

Interpretación: Solo aumentará si la nueva variable mejora el modelo más de lo que se esperaría por simple azar. Si agregas ruido, el R^2_{adj} disminuirá.