Regresión Polinomial

Presentado por:
Rubén Manrique

Universidad de los Andes
Departamento de Ingeniería de Sistemas y Computación

Curso: Aprendizaje de Máquina
Semestre: 2026-10

14 de febrero de 2026

La Limitación de la Linealidad

- **Supuesto:** La regresión lineal simple ($y = \beta_0 + \beta_1 x$) asume cambios constantes.
- **Realidad:** Fenómenos como epidemias o física de partículas suelen mostrar curvatura.
- **Problema:** Subajuste (Underfitting) sistemático.

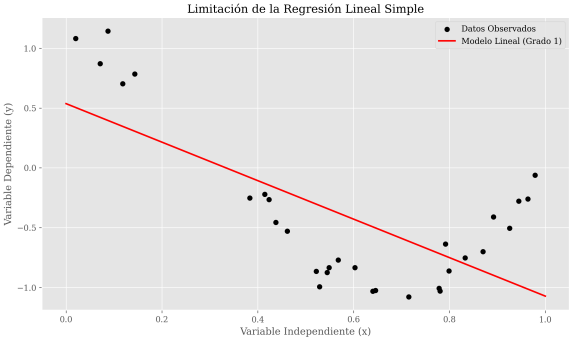

Figura: Fallo del ajuste lineal en datos curvos.

Definición de Regresión Polinomial

Concepto

Modelo lineal general donde la relación entre x e y se modela como un polinomio de grado n.

Fórmula:

$$y = \beta_0 + \beta_1 x + \beta_2 x^2 + \cdots + \beta_n x^n + \epsilon$$

Importante

Es lineal respecto a los coeficientes β, lo que permite usar Mínimos Cuadrados Ordinarios (OLS).

Efecto del Grado del Polinomio (d)

El grado determina la flexibilidad de la curva:

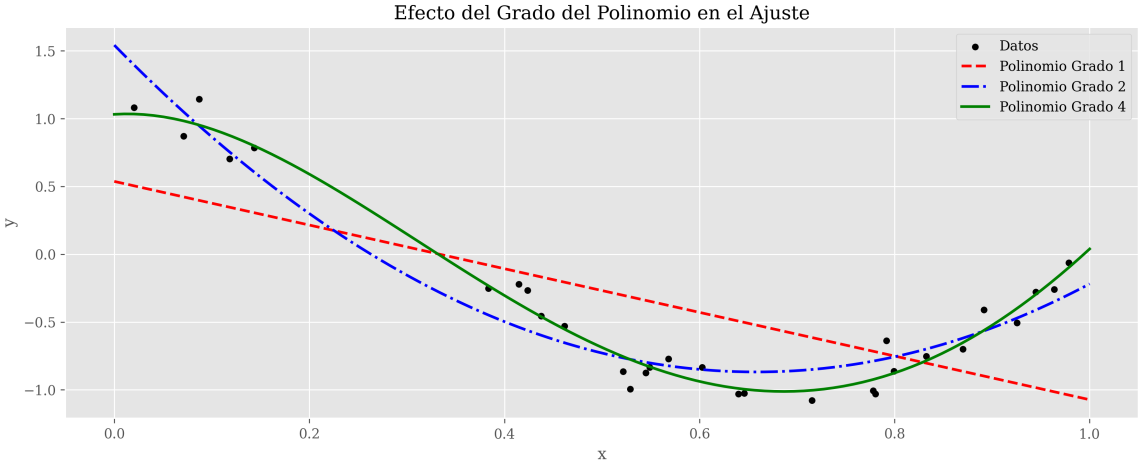

Figura: Comparación: Grado 1 (Rígido) vs Grado 4 (Flexible).

El Peligro del Sobreajuste (Overfitting)

Fenómeno de Runge:

- Con d muy alto, el modelo *oscila* para tocar todos los puntos.
- Captura el **ruido**, no la señal.
- Pésima generalización en datos nuevos.

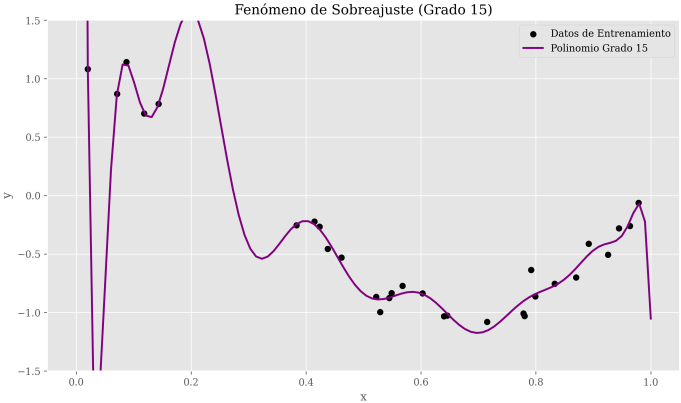

Figura: Polinomio de Grado 15 ajustando ruido.

El Dilema Sesgo-Varianza

Buscamos minimizar el Error Total:

$$E = \text{Sesgo}^2 + \text{Varianza} + \text{Error Irreducible}$$

Estado	**Características**	**Solución**
Subajuste	Alto Sesgo	Aumentar grado d
Sobreajuste	Alta Varianza	Regularizar o más datos
Óptimo	Equilibrio	Validación Cruzada

De una a múltiples dimensiones

Hasta ahora vimos polinomios con una sola variable x:

$$y = \beta_0 + \beta_1 x + \beta_2 x^2$$

¿Qué sucede si tenemos dos variables/caracteristicas de entrada, x_1 y x_2?

Error Común

Pensar que la expansión polinomial es solo elevar al cuadrado cada variable independientemente:

$$y \neq \beta_0 + \beta_1 x_1 + \beta_2 x_1^2 + \beta_3 x_2 + \beta_4 x_2^2 \quad \text{(Esto está incompleto)}$$

Falta capturar cómo x_1 y x_2 se relacionan entre sí: las **Interacciones**.

La Expansión Polinomial Completa (Grado 2)

Para dos variables (x_1, x_2) y grado $d = 2$, el modelo completo es:

$$y = \underbrace{\beta_0}_{\text{Bias}} + \underbrace{\beta_1 x_1 + \beta_2 x_2}_{\text{Términos Lineales}} + \underbrace{\beta_3 x_1^2 + \beta_4 x_2^2}_{\text{Términos Cuadráticos}} + \underbrace{\beta_5 x_1 x_2}_{\text{Interacción}} \tag{1}$$

Interpretación de la Interacción ($x_1 x_2$):

- Indica que el efecto de x_1 sobre y depende del valor de x_2.
- Ejemplo: El impacto de la "Lluvia"(x_1) en el "Tráfico"(y) es mucho peor si es "Hora Pico"(x_2).

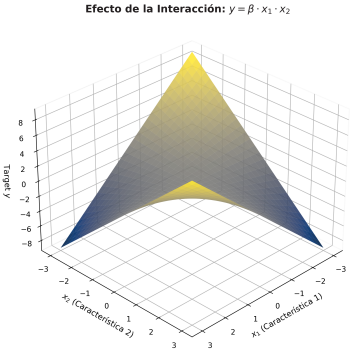

Figura: Superficie de Interacción ($x_1 \cdot x_2$).

¿Cómo funciona PolynomialFeatures?

Esta herramienta transforma nuestro espacio de características original en uno de mayor dimensión.

Input (X)
$[a, b]$

→ `PolynomialFeatures(degree=2)` →

Output (X_{poly})
$[1, a, b, a^2, ab, b^2]$

- Genera automáticamente todas las combinaciones posibles hasta el grado d.
- Incluye por defecto la columna de unos (Intercepto/Bias).

Implementación en Python

```python
from sklearn.preprocessing import PolynomialFeatures
import numpy as np

# Datos: 2 muestras, 2 características (a, b)
X = np.array([[2, 3],
              [4, 5]])

# Expandir a Grado 2
poly = PolynomialFeatures(degree=2, include_bias=False)
X_poly = poly.fit_transform(X)

print(poly.get_feature_names_out(['a', 'b']))
```

Salida esperada:

Nombres de las nuevas columnas

`['a', 'b', 'a^2', 'a b', 'b^2']`

Noten que el término `'a b'` es la interacción generada automáticamente.

Crecimiento Combinatorio

Al aumentar el número de características originales (n) y el grado (d), el número de características resultantes (N_{feat}) crece factorialmente.

$$N_{feat} = \binom{n+d}{d}$$

Variables Originales (n)	Grado (d)	**Variables Finales**	Ejemplo
2	2	**6**	$1, a, b, a^2, ab, b^2$
5	2	**21**	...
10	3	**286**	...
20	4	**10,626**	¡Peligro de Overfitting!

Advertencia

Usar 'PolynomialFeatures' con muchas variables de entrada requiere casi obligatoriamente usar **Regularización** (Lasso/Ridge) para controlar la explosión de coeficientes.

Puntos Clave

1. **Interacciones:** La regresión polinomial multivariable captura cómo las variables se afectan entre sí ($x_1 x_2$), no solo sus potencias individuales.
2. **Linealidad:** A pesar de la complejidad, el problema sigue siendo una Regresión Lineal sobre las nuevas características X_{poly}.
3. **Cuidado:** El número de columnas crece muy rápido.
   - Grado 2 es usualmente suficiente.
   - Grado 3+ es riesgoso sin muchos datos.

¿Preguntas sobre la expansión?

Estrategias de Selección y Regularización

1. **Validación Cruzada (K-Fold):** Evaluar diferentes grados d en conjuntos de validación para encontrar el óptimo.
2. **Regularización (Ridge / Lasso):** Penalizar coeficientes grandes para suavizar la curva polinomial sin reducir drásticamente el grado.
3. **Datos:** Aumentar el tamaño de la muestra (N) permite usar polinomios de mayor grado con menor riesgo.

Aplicaciones Reales

- **Epidemiología:** Curvas de crecimiento de contagios (fases tempranas).
- **Finanzas:** Modelado de la estructura temporal de tasas de interés.
- **Ingeniería:** Relación tensión-deformación en materiales plásticos.
- **Física:** Calibración de sensores no lineales.