Universidad de los Andes Colombia | Departamento de Ingeniería de Sistemas y Computación

Tipos de Aprendizaje y ciclo típico de ML

Reconocimiento como Universidad: Decreto 1297 del 30 de mayo de 1964.
Reconocimiento personería jurídica: Resolución 28 del 23 de febrero de 1949 Minjusticia

Agenda

- Tipos de aprendizaje, con ejemplos de casos de uso.
- Proceso de aprendizaje a partir de datos.
- Ejemplos de proyectos de aprendizaje de máquina.

Simbólica (ejemplo I)

El niño juega con la pelota.

Datos

Reglas

Salida

El (**ART**)
niño (**SUS**)
juega (**VER**)
con (**PRE**)
la (**ART**)
pelota
(**SUS**)

- Sintácticas:
  - O --> SN SV
  - SN --> (Determinante) (cuantificador) sustantivo/pronombre /nada (adverbio) (adjetivo)*
- Diccionario
  - Artículos - Determinantes

Universidad de los Andes Colombia
Departamento de Ingeniería de Sistemas y Computación

Simbólica (ejemplo I)

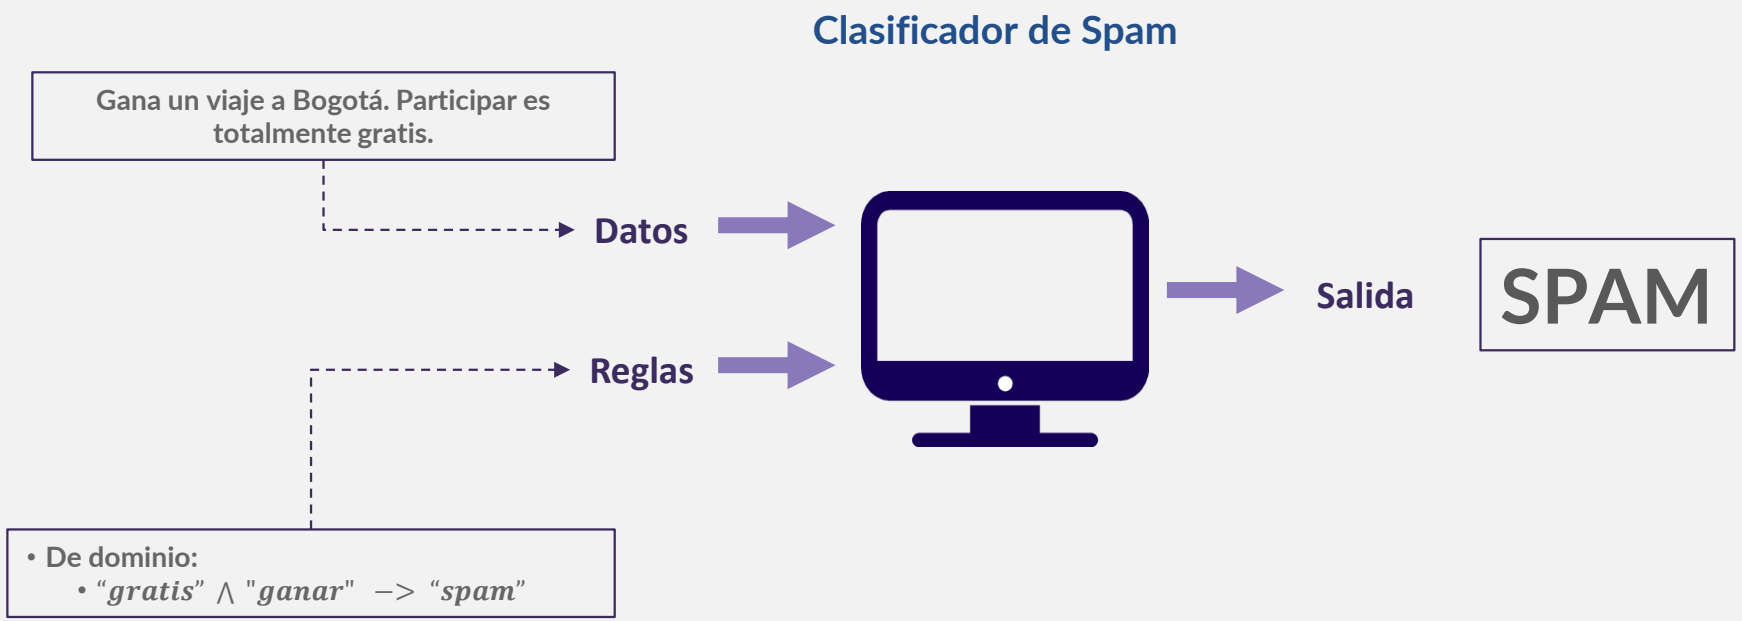

Rápidamente se dieron cuenta de la necesidad de utilizar representaciones formales en la definición del conocimiento de dominio -> reutilización de reglas

Limitaciones y ventajas de los enfoques basados en reglas

- Limitaciones:
  - Requieren de conocimiento experto humano para generar reglas.
  - Aún para tareas de baja complejidad, la generación de reglas es una tarea extenuante (cientos de reglas).
- Ventajas
  - La salida de un modelo basado en reglas es explicable y auditable.

Universidad de los Andes Colombia
Departamento de Ingeniería de Sistemas y Computación

Enfoque basado en datos (Aprendizaje de máquina)

Universidad de los Andes Colombia
Departamento de Ingeniería de Sistemas y Computación

Enfoque basado en datos

ACEROUS

NON-ACEROUS

?

?

El caballo a que categoría pertenece?

Universidad de los Andes Colombia
Departamento de Ingeniería de Sistemas y Computación

Las reglas se construyen con técnicas de IA

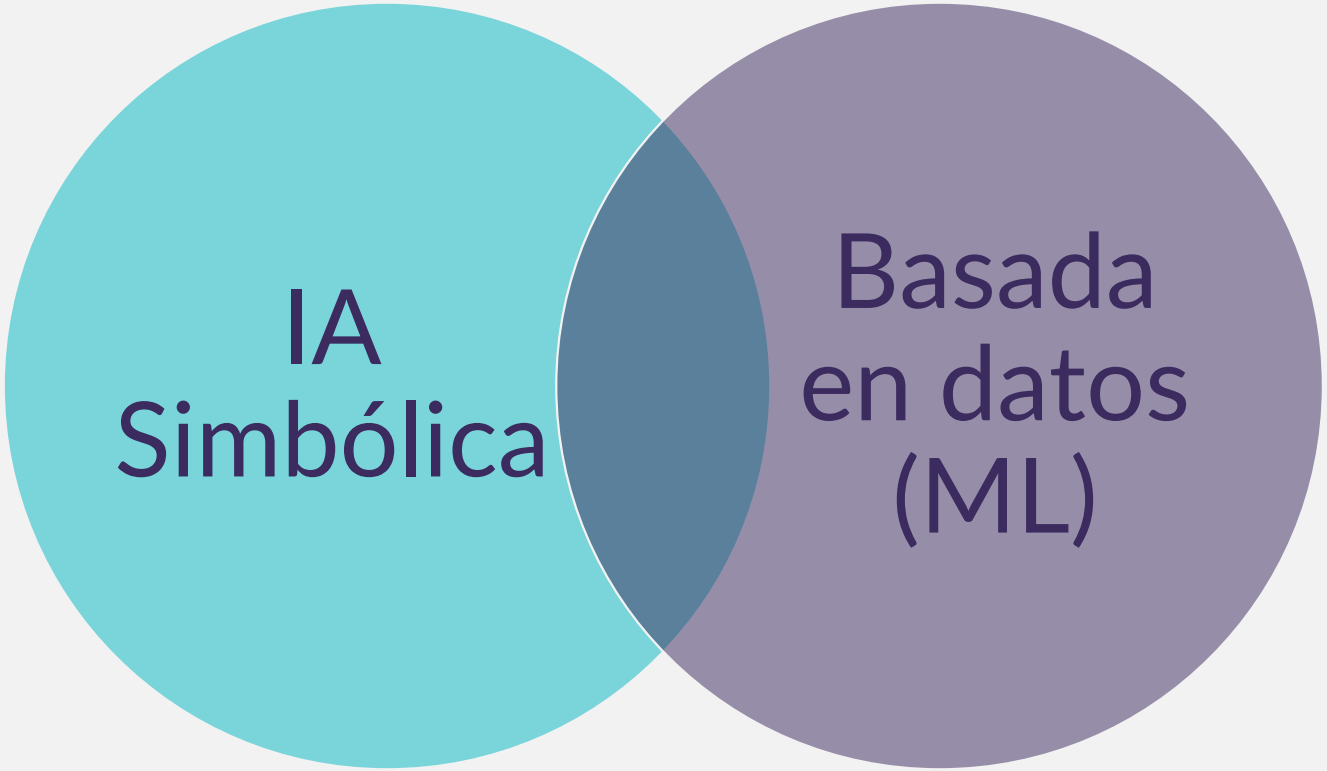

Universidad de los Andes Colombia
Departamento de Ingeniería de Sistemas y Computación

Enfoque basado en datos (evolución)

Una rama de la inteligencia artificial donde la regresión, las inferencias y las "reglas" de clasificación están determinadas por los datos ... en lugar de estar "programadas" explícitamente.

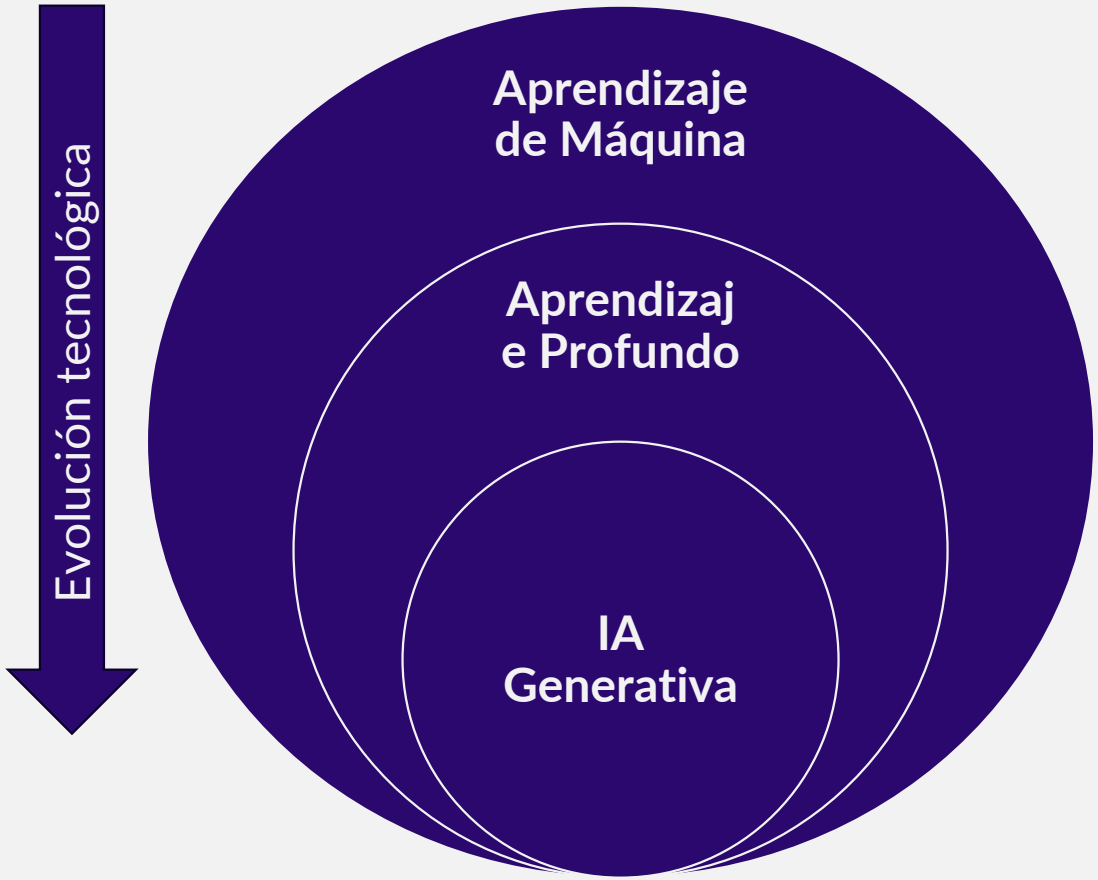

Universidad de los Andes Colombia
Departamento de Ingeniería de Sistemas y Computación

Enfoque basado en datos (tipos)

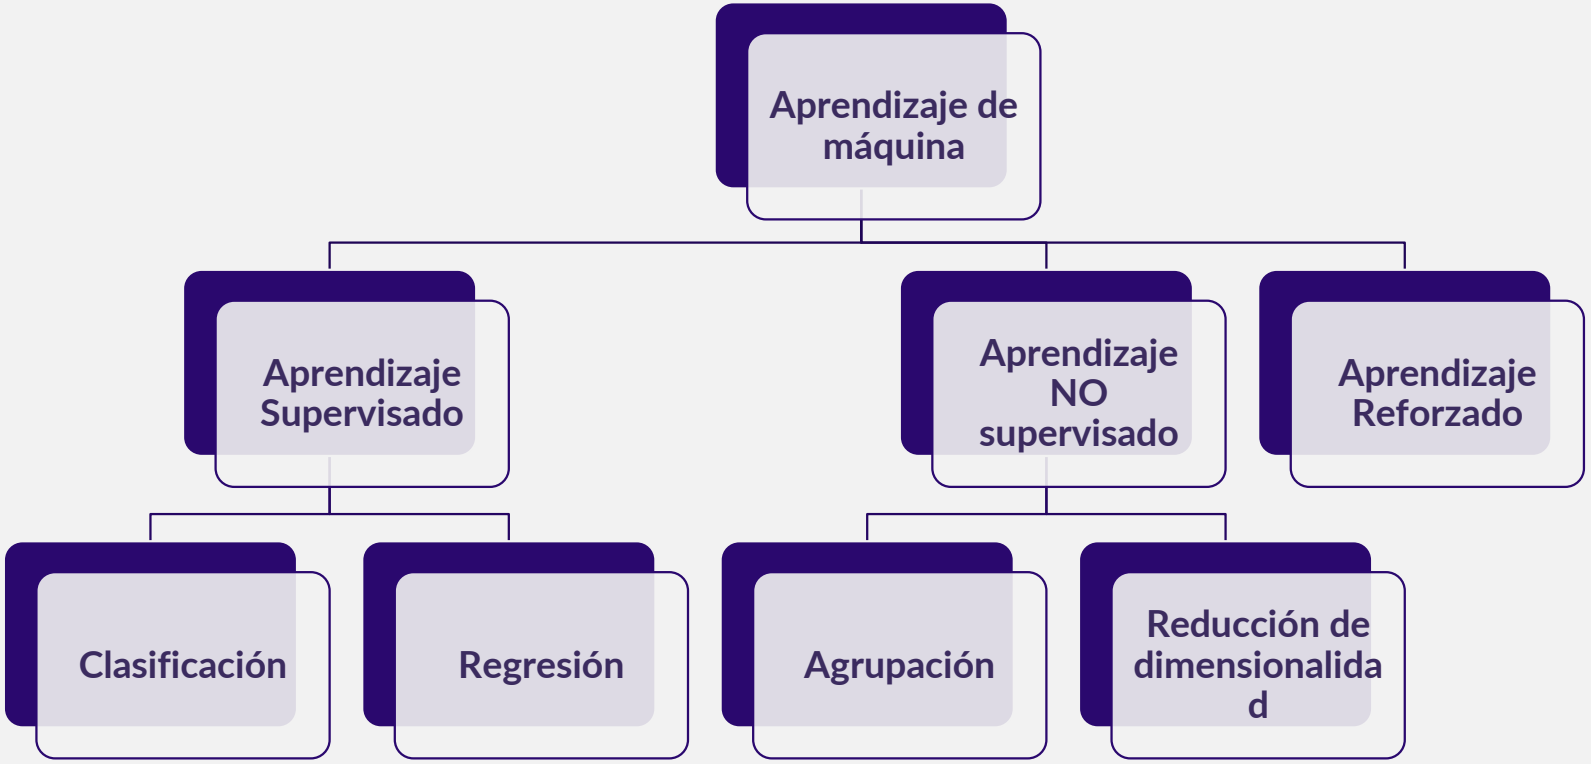

Universidad de los Andes Colombia
Departamento de Ingeniería de Sistemas y Computación

Aprendizaje de Máquina (aprendizaje supervisado)

- En los datos de entrenamiento existe una señal de supervisión que nos permite guiar el aprendizaje.

- Señal de supervisión
  - Etiqueta categórica -> Clasificación
  - Número real -> Regresión

- Que tipo de aprendizaje supervisado son las siguientes tareas:
  - Identificar un correo en spam o no spam? Clasificación
  - Predecir el peso de una persona en base a su altura y edad? Regresión
  - Identificar si en una imagen hay una cara de un persona o no la hay? Clasificación
  - Determinar los niveles de azúcar en la sangre a partir de dieta? Regresión

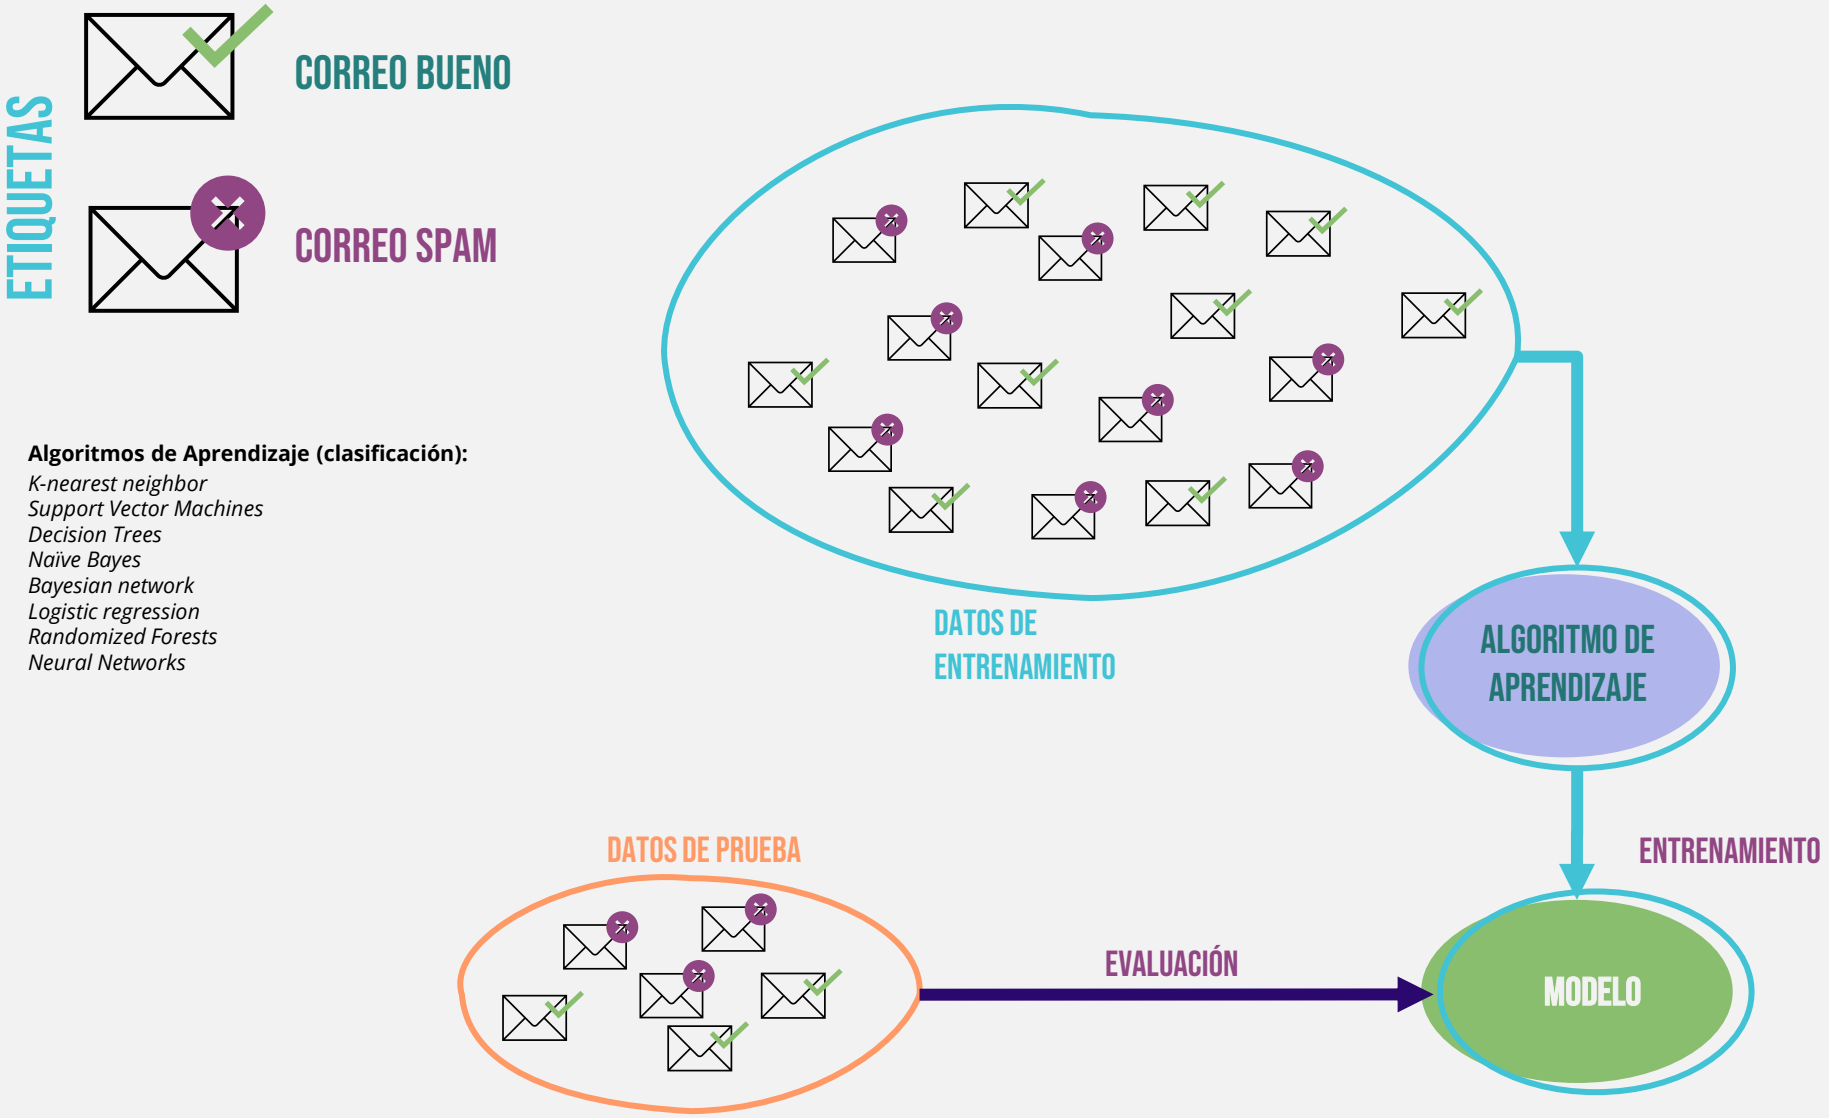

Algoritmos de Aprendizaje (clasificación):

K-nearest neighbor
Support Vector Machines
Decision Trees
Naïve Bayes
Bayesian network
Logistic regression
Randomized Forests
Neural Networks

Universidad de los Andes Colombia
Departamento de Ingeniería de Sistemas y Computación

OBJETIVO: PREDECIR LA ALTURA DE LO NIÑOS EN BASE A SU EDAD Y LUGAR DE NACIMIENTO

Señal de supervisión: Altura (cm)

Algoritmos de Aprendizaje (regresión):

Linear regression
Support Vector Regression
Decision Trees Regressor
Bayesian Regression
Adaboosting
Neural Networks

DATOS DE ENTRENAMIENTO

Edad	País	Altura (cm)
1	Colombia	75
2	Costa Rica	85
3	Perú	95
4	Chile	102
5	Argentina	109
6	Colombia	115
7	Costa Rica	120
		...

ALGORITMO DE APRENDIZAJE

MODELO

DATOS DE PRUEBA

Edad	País	Altura (cm)
1	Colombia	75
2	Costa Rica	85

Aprendizaje basado en Instancia vs Modelo

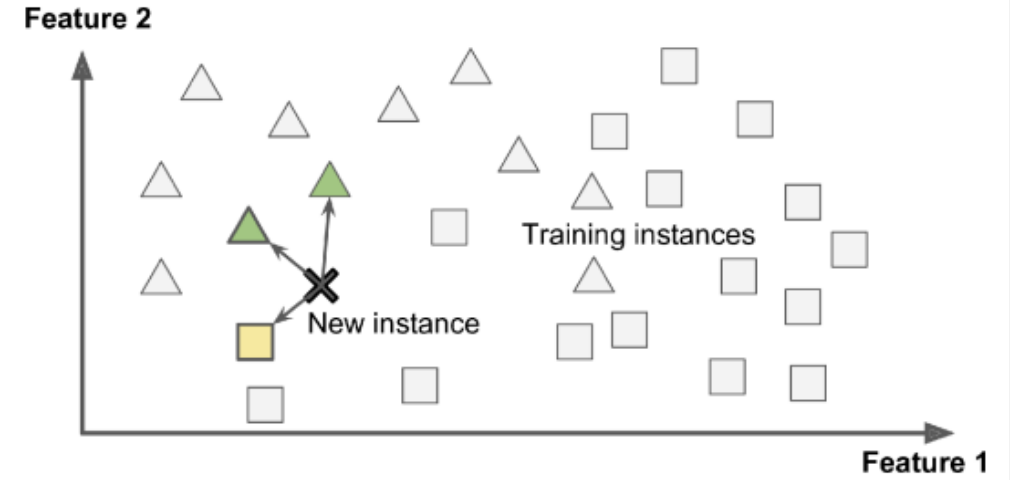

Uso de instancias similares para determinar el label

Se aprende una función de decisión

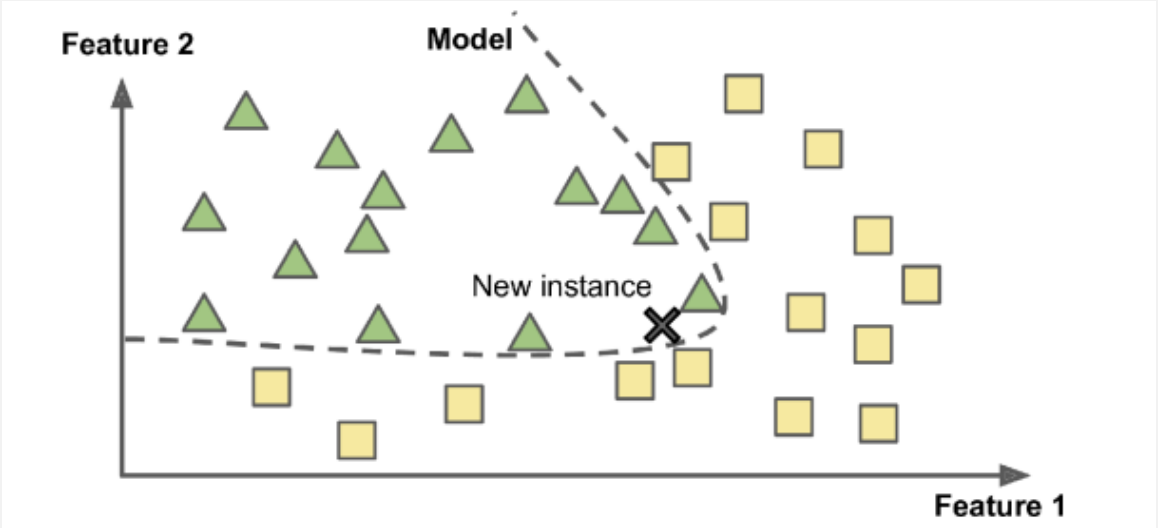

Universidad de los Andes Colombia
Departamento de Ingeniería de Sistemas y Computación

Aprendizaje de Máquina (aprendizaje supervisado)

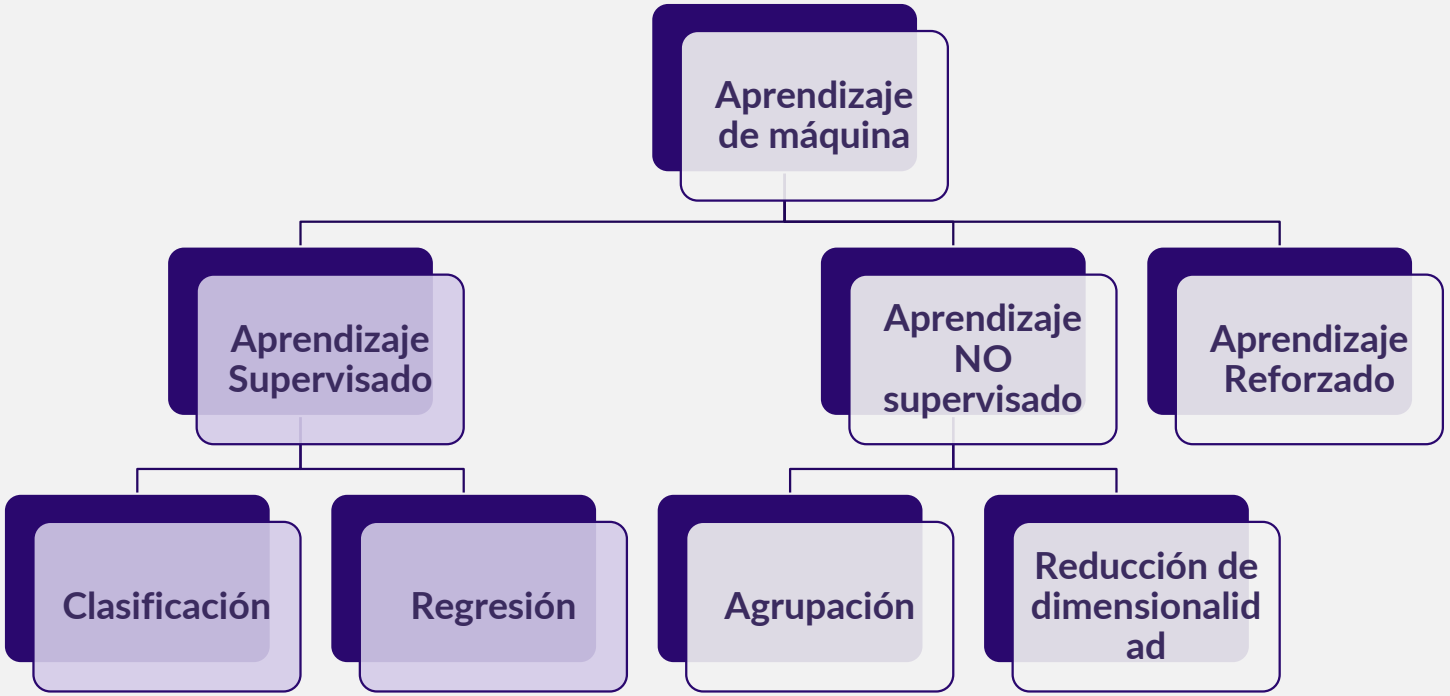

Universidad de los Andes Colombia
Departamento de Ingeniería de Sistemas y Computación

Aprendizaje de Máquina (aprendizaje NO supervisado)

No hay una señal de supervisión!, la idea es describir los datos, generalmente Construyendo grupos (clustering).

Como organizarían estos elementos?

Universidad de los Andes Colombia
Departamento de Ingeniería de Sistemas y Computación

Aprendizaje de Máquina (aprendizaje NO supervisado)

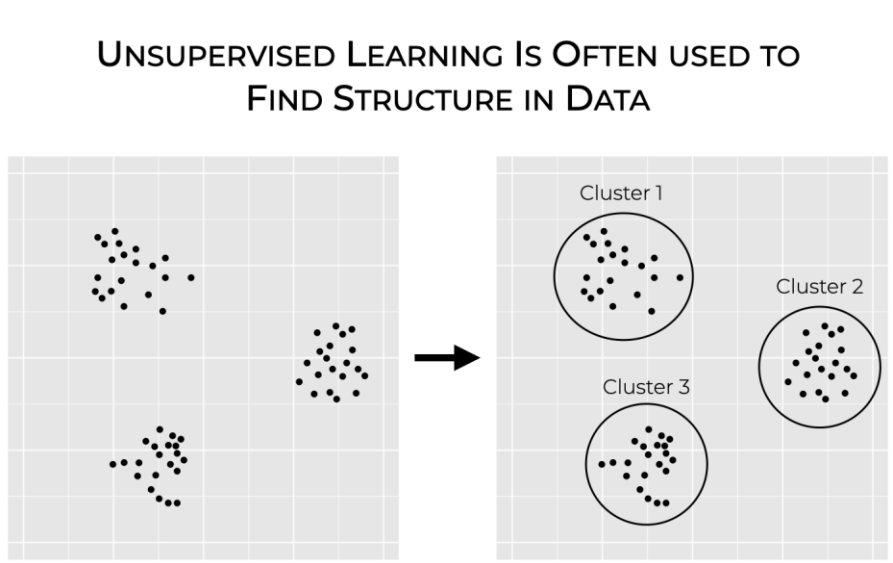

Imagen tomada de https://sharpsight.ai/

Los grupos se forman en base: a la distancia en el espacio de características (=**características comunes**)

HACER AGRUPAMIENTOS SIN ETIQUETAS

Universidad de los Andes Colombia
Departamento de Ingeniería de Sistemas y Computación

Aprendizaje de Máquina (aprendizaje NO supervisado)

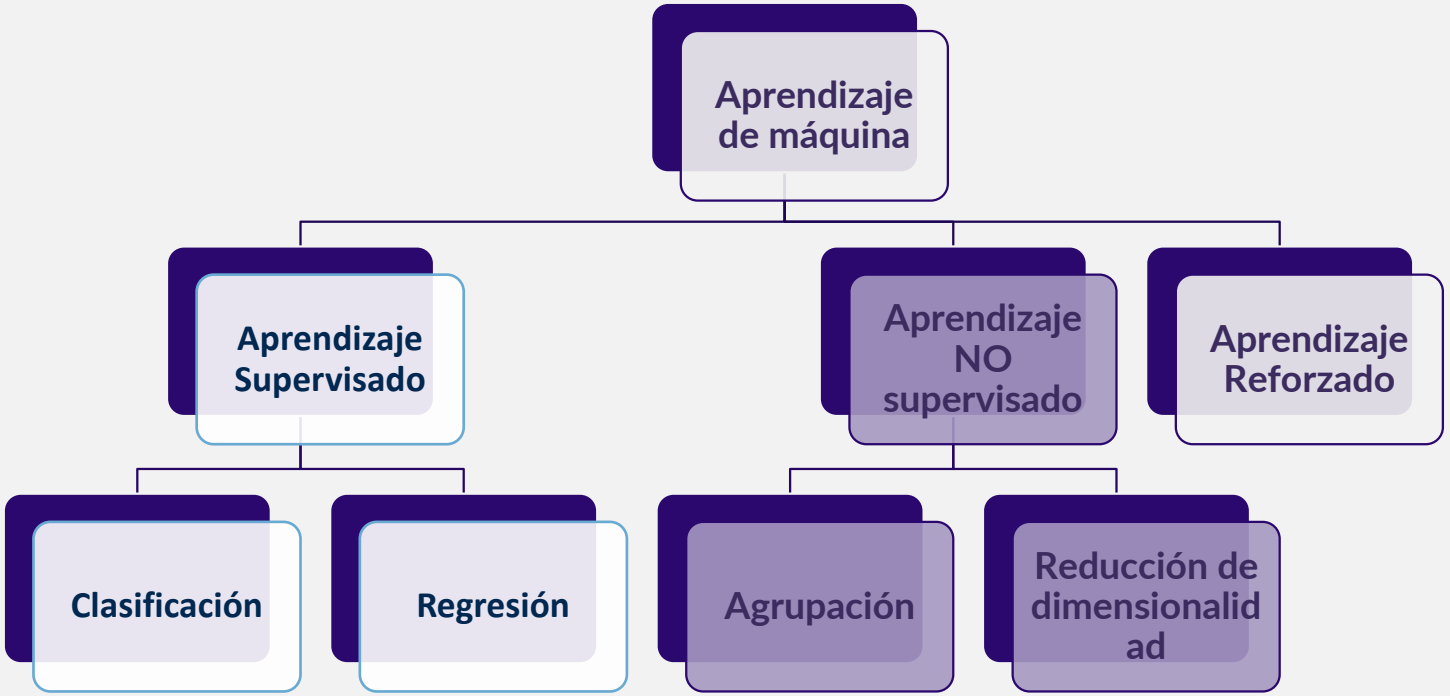

Universidad de los Andes Colombia
Departamento de Ingeniería de Sistemas y Computación

Aprendizaje por refuerzo

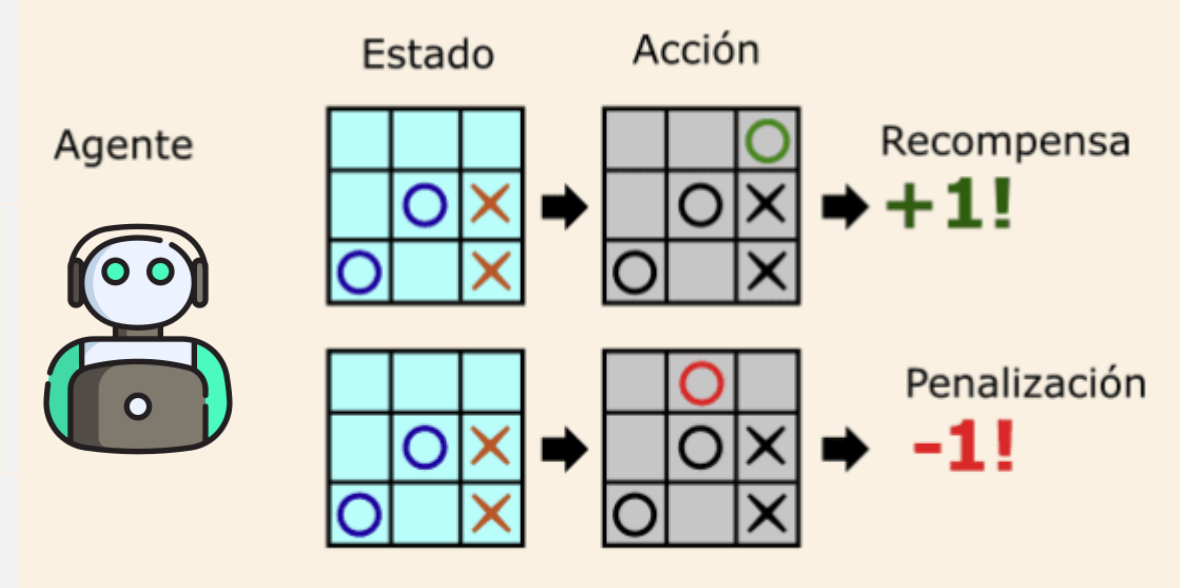

Imagen tomada de
https://www.ceupe.com/

El **aprendizaje por refuerzo** es un paradigma del aprendizaje automático en el que un **agente** aprende a **tomar decisiones** mediante la interacción con un **entorno**, recibiendo recompensas o penalizaciones según sus acciones.

Agentes

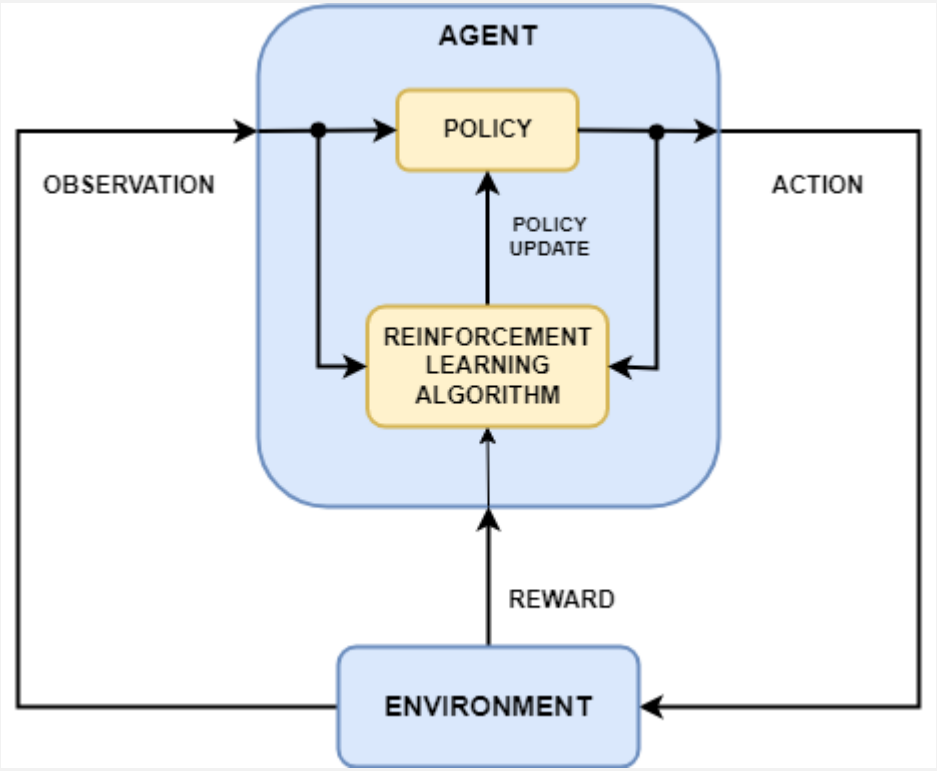

Tomado de
https://in.mathworks.com/

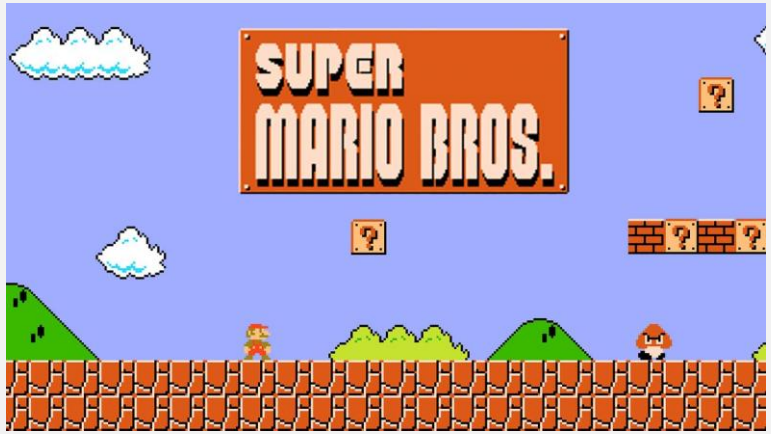

Universidad de los Andes Colombia
Departamento de Ingeniería de Sistemas y Computación

Retos del aprendizaje de Máquina

Universidad de los Andes Colombia
Departamento de Ingeniería de Sistemas y Computación

Insuficiente cantidad de datos

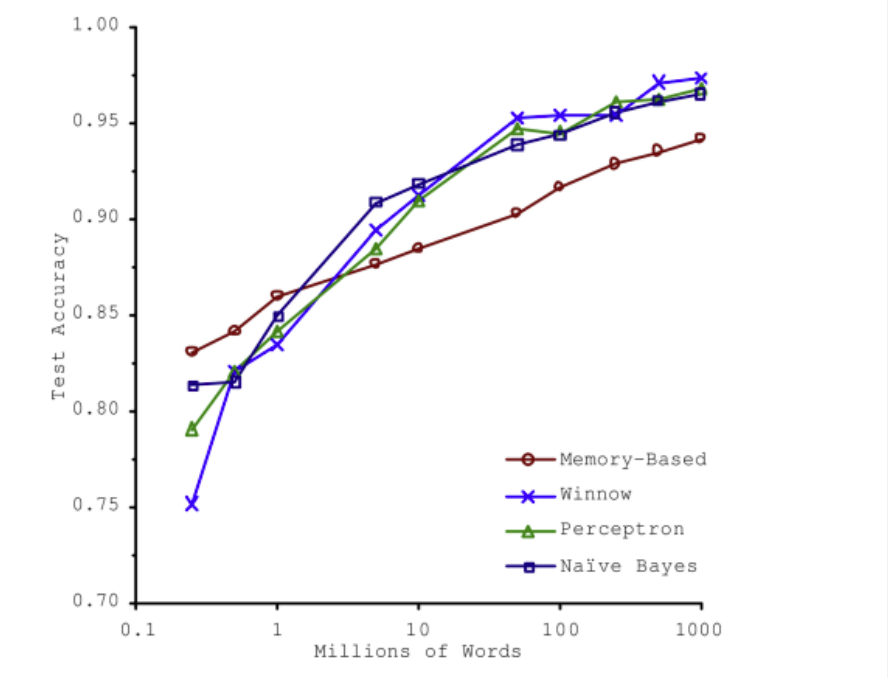

Los investigadores de Microsoft, Michele Banko y Eric Brill, demostraron que algoritmos de aprendizaje automático muy diferentes, incluidos algunos bastante simples, funcionaron casi idénticamente bien en un problema complejo de desambiguación del lenguaje natural8 una vez que se les proporcionaron suficientes datos.

Michele Banko and Eric Brill. 2001. Scaling to very very large corpora for natural language disambiguation. In Proceedings of the 39th Annual Meeting on Association for Computational Linguistics (ACL '01). Association for Computational Linguistics, USA, 26–33. https://doi.org/10.3115/1073012.1073017

Datos no representativos

Tomada del libro de Geron

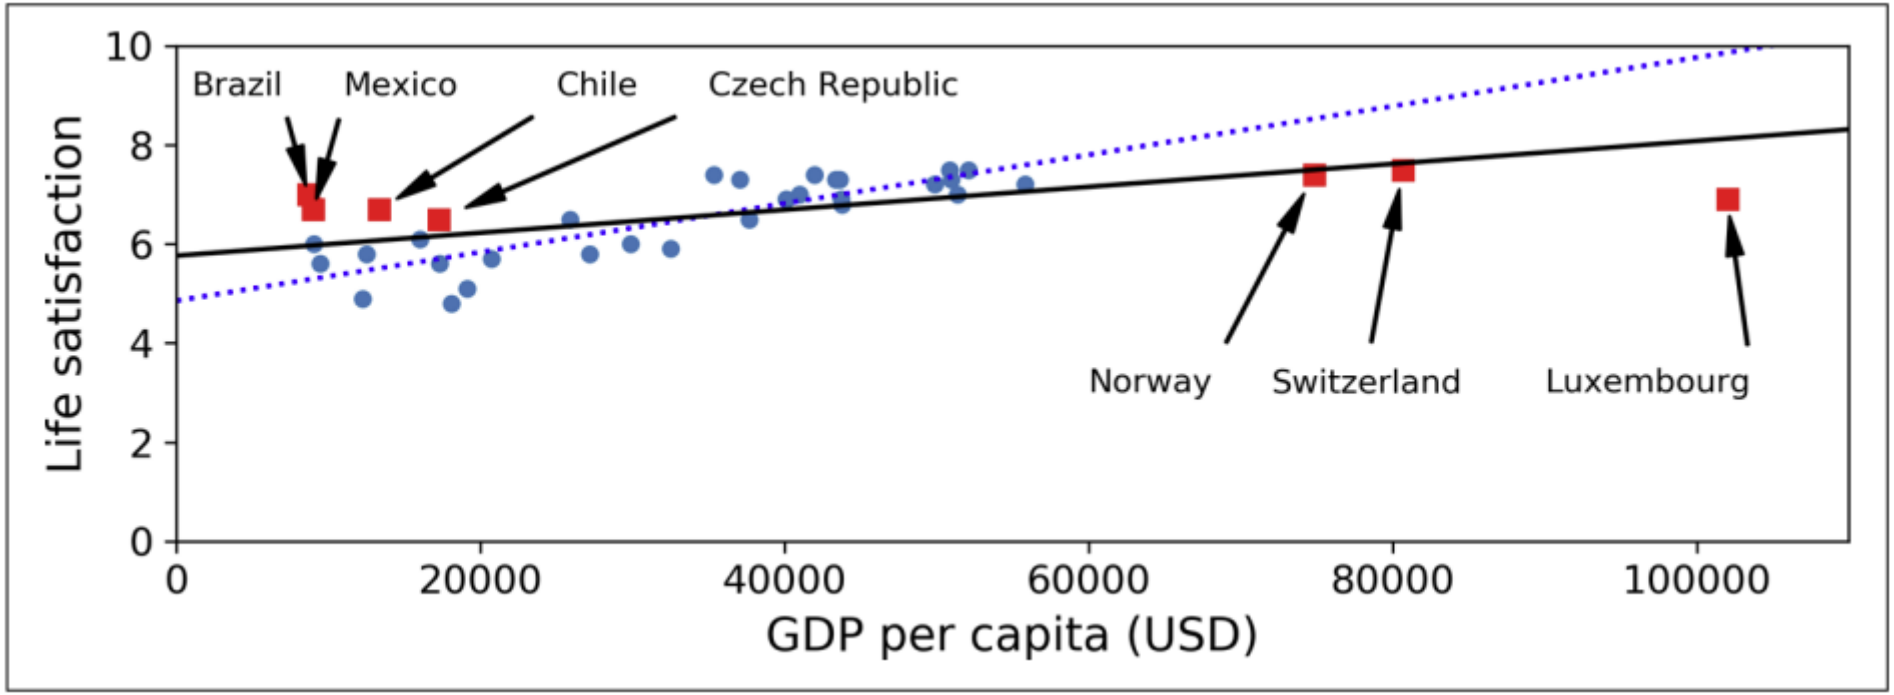

Para generalizar correctamente, es fundamental que los datos de entrenamiento sean representativos de los nuevos casos a los que se desea generalizar. Esto aplica tanto al aprendizaje basado en instancias como al aprendizaje basado en modelos.

Sesgo de muestra

Universidad de los Andes Colombia
Departamento de Ingeniería de Sistemas y Computación

Otros (se abordaran en detalle mas adelante)

- Datos sin calidad
- Características irrelevantes
- Sobreajuste de los datos de entrenamiento

Ciclo del Aprendizaje de Máquina

Universidad de los Andes Colombia
Departamento de Ingeniería de Sistemas y Computación

APRENDIZAJE DE MÁQUINAS

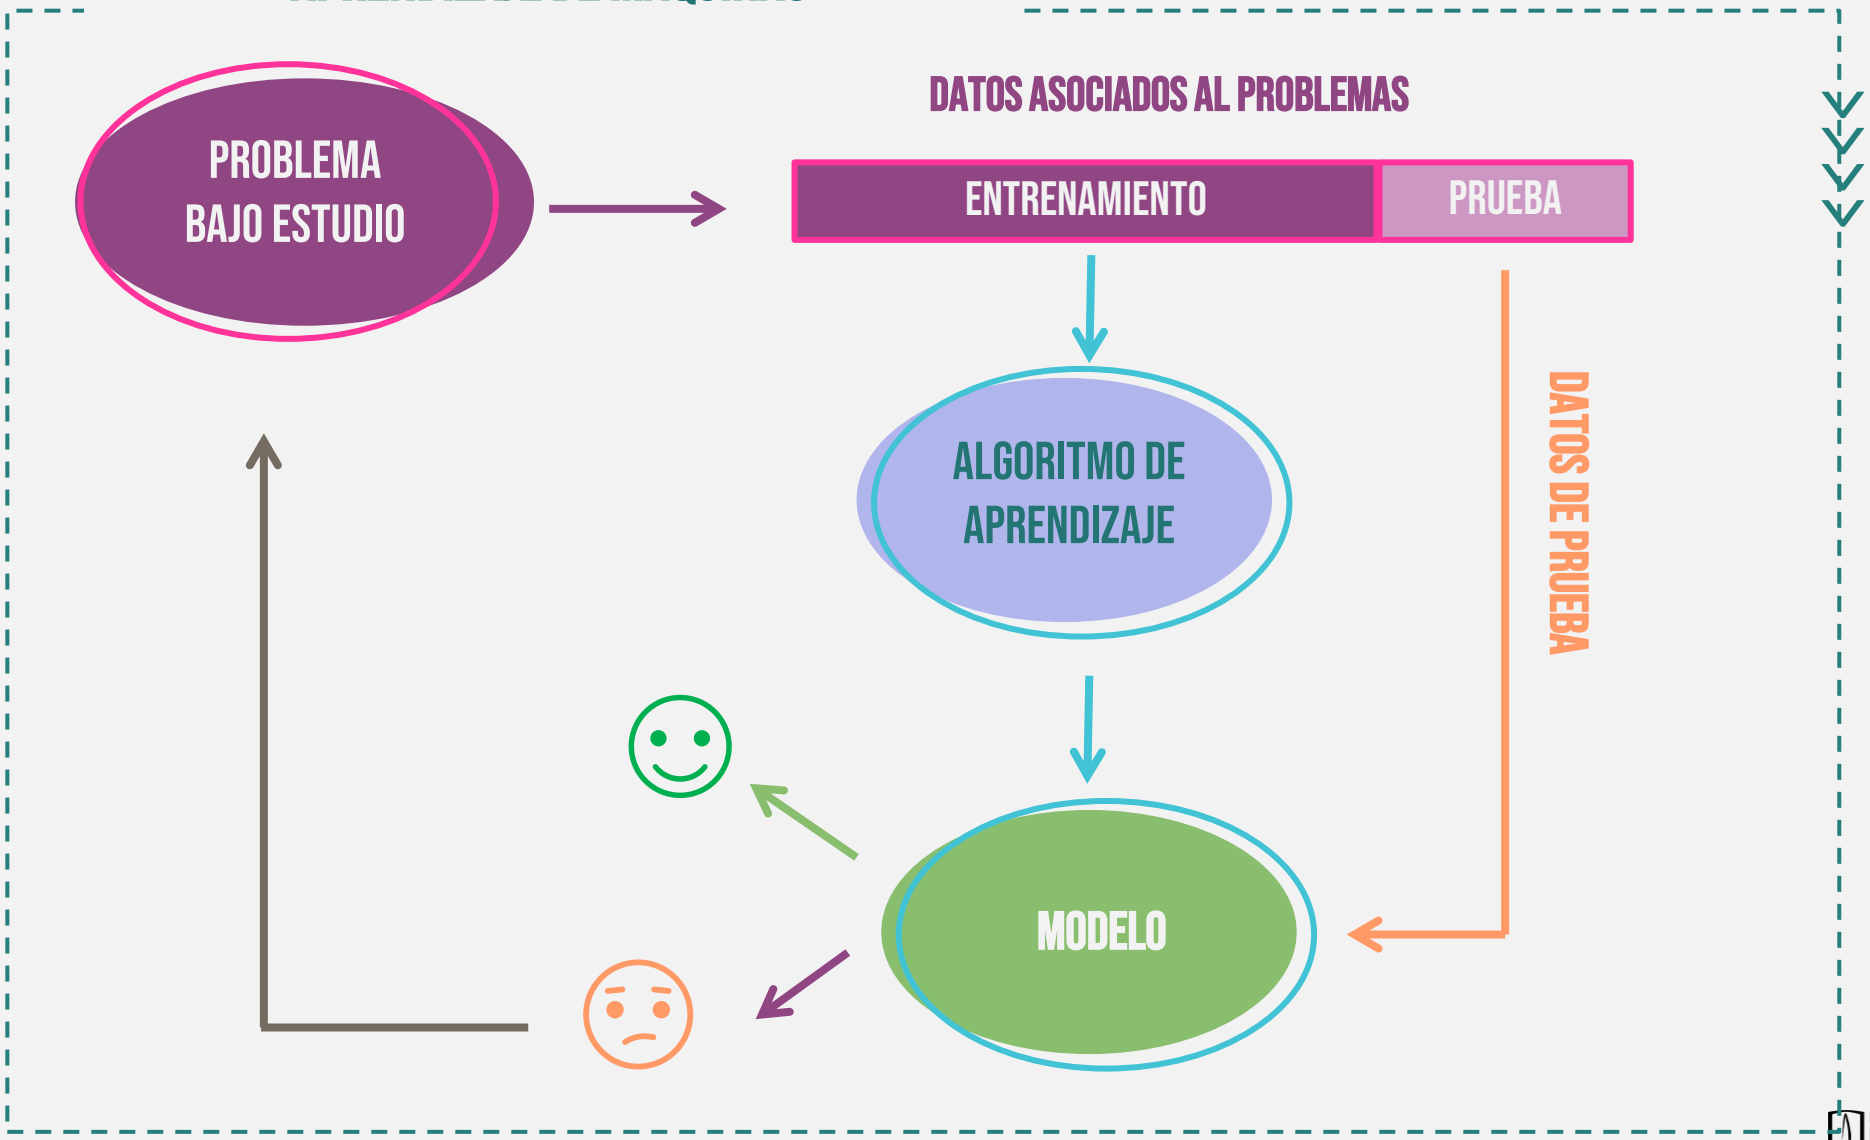

Universidad de los Andes Colombia
Departamento de Ingeniería de Sistemas y Computación

Se puede tener un aprendizaje continuo
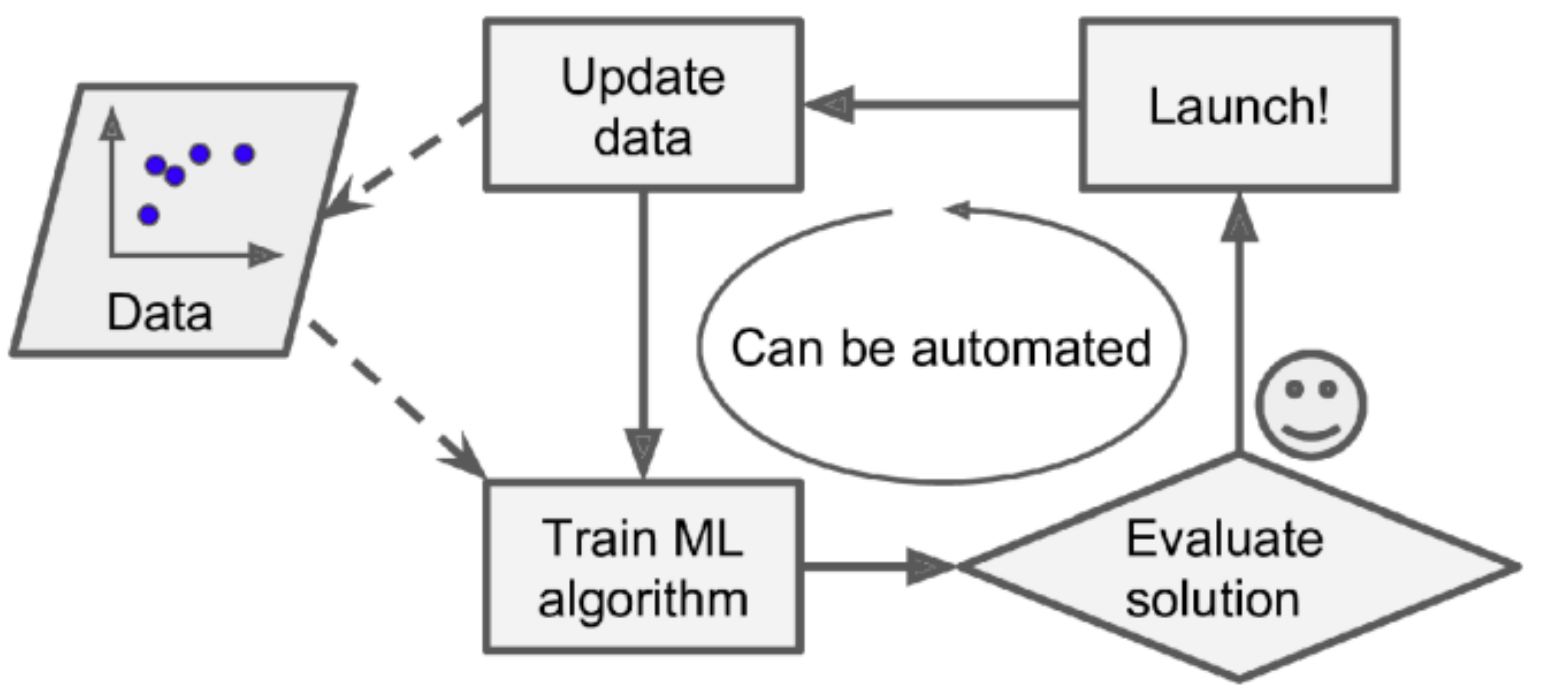
Tomada del libro de Geron