Universidad de los Andes Colombia | Departamento de Ingeniería de Sistemas y Computación

Tipos de conjuntos de datos
Sesgos en el aprendizaje

Reconocimiento como Universidad: Decreto 1297 del 30 de mayo de 1964.
Reconocimiento personería jurídica: Resolución 28 del 23 de febrero de 1949 Minjusticia

Agenda

- Tipos de conjuntos de datos y su representación.
- Algunos sesgos en el aprendizaje. El sesgo de muestra.
- Exploración de los datos.

Característica (feature)

- Una **característica** (feature) es una propiedad, atributo o variable medible de los datos que se utiliza como entrada para los modelos de Machine Learning.
- Cada característica representa una columna en el conjunto de datos.

Características | Label/etiqueta

Tamaño (m²)	Habitaciones	Ubicación	Precio ($)
80	2	Centro	100,000
120	3	Suburbios	150,000

Características / Variables independientes: Tamaño, Habitaciones, Ubicación
Variable dependiente: Precio

Ejemplos

- **Clasificación de clientes bancarios**
  - Edad, Ingresos mensuales, Historial crediticio, Número de productos contratados
- **Diagnóstico hipertensión**
  - Presión arterial, Nivel de glucosa, Edad del paciente, Género, Resultados de análisis de sangre
- **Detección de fraude en transacciones**
  - Monto de la transacción, Hora del día, Ubicación del comercio, Tipo de tarjeta usada , Historial de transacciones previas

Importante

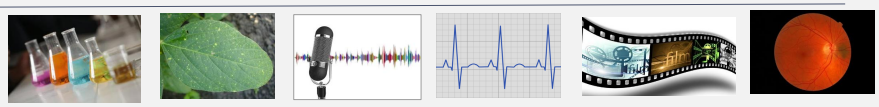

Atributo$_1$	Atributo$_2$	Atributo$_3$	Atributo$_4$	Atributo$_5$	Atributo$_6$	.....	Atributo$_d$
⋮							

- Instancia.
- Ejemplo.
- Registro
- Caso
- Observación.

- Atributo.
- Variable.
- Característica
- Dimensión.

Representación que el algoritmo de aprendizaje pueda procesar

Tipos de conjuntos de datos y su representación

Datos

- **Diferentes orígenes**
  - Sistemas transaccionales
  - Sistemas de análisis (Bodegas de datos, Bodegas de lagos de datos).
  - Redes sociales.
- **Diferentes almacenamientos y modelos**
  - Modelos relacional.
  - Modelos NoSQL.
  - Modelos de grafos.
  - Modelos vectoriales.
- **Conocer los orígenes y la forma de analizar los datos según su tipo permite**
  - Determinar formas de prepararlos y transformarlos para utilizar algoritmos de aprendizaje automático.
  - Determinar los siguientes pasos en el proceso analítico.
  - Interpretar los resultados del proyecto de aprendizaje automático.

❑ Datos tabulares

Normalmente provienen de sistemas diseñados para registrar, controlar y medir procesos.

Son fuentes donde los datos nacen estructurados en filas y columnas, no se "transforman" después.

Sistemas transaccionales | Bases de datos relacionales | Bodegas de datos | Hojas de cálculo | Encuestas o formularios | .....

Datos

Atributo$_1$	Atributo$_2$	Atributo$_3$	Atributo$_4$	Atributo$_5$	Atributo$_6$	.....	Atributo$_d$
⋮							

- Atributo.
- Variable.
- Característica
- Dimensión.

- Cualitativas
  - Nominales
  - Ordinales
- Cuantitativas
  - Discretas
  - Continuas

❑ Cualitativos (Categóricos)

Nominales: No tienen un orden específico.

Ejemplos:

Color: rojo, azul, verde

Género: masculino, femenino

Ordinales: Tienen un orden, pero no hay distancia numérica entre categorías.

Ejemplos:

Talla: pequeño, mediano, grande

Nivel educativo: primaria, secundaria, universidad

❑ Cualitativos (Numéricos)

Discretos: Solo toman valores enteros (no fracciones).

- Ejemplos:
  - Número de hijos
  - Cantidad de productos comprados

Continuos: Pueden tomar cualquier valor dentro de un rango, incluyendo decimales.

- Ejemplos:
  - Estatura (en metros)
  - Peso (en kilogramos)
  - Tiempo (en segundos)

❑ Imágenes

Las imágenes no tienen una estructura tabular.
Cada imagen contiene información visual y espacial.
En general, requieren procesos de transformación antes de ser analizadas por modelos.
Pueden variar significativamente en resolución, formato y calidad..

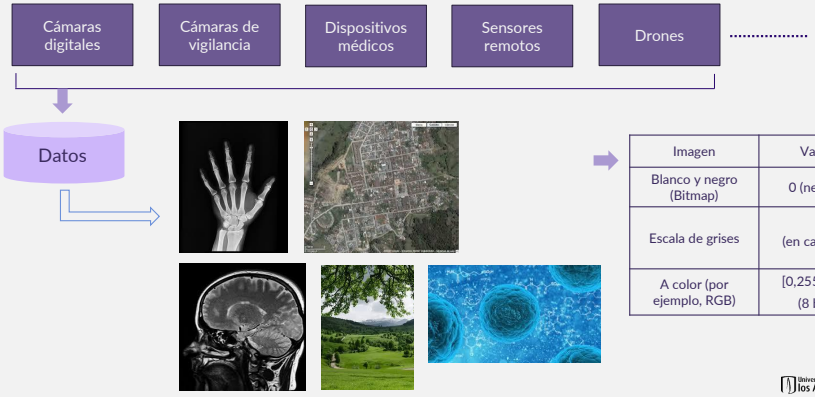

Imagen	Valores de píxel
Blanco y negro (Bitmap)	0 (negro), 1 (blanco)
Escala de grises	[0, 255] (en caso de 8 bits por píxel)
A color (por ejemplo, RGB)	[0,255] por cada canal (8 bits por canal)

❑Bitmap

1	0	1	1	0	1
0	1	0	0	1	0
0	1	1	1	1	0
0	1	1	1	1	0
1	0	1	1	0	1
1	1	0	0	1	1

❑Escala de grises

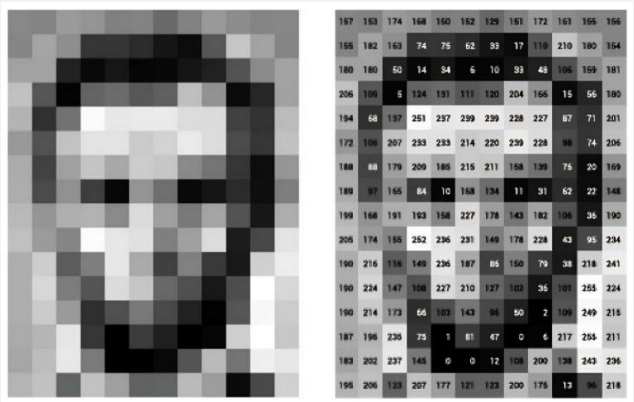

❑Colores (RGB)

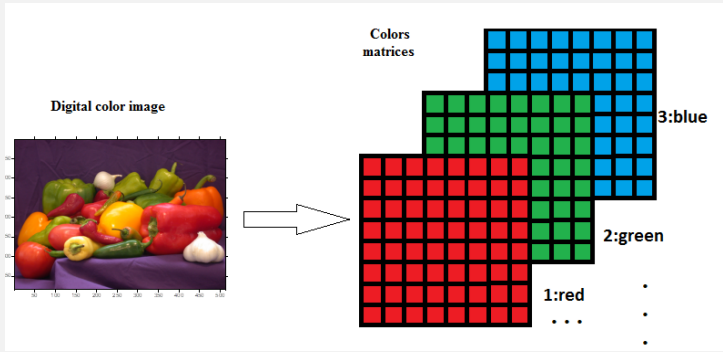

(520,400,3)

Ejemplo: una forma directa de obtener representaciones vectoriales (una dimensión) a partir de las matrices (dos dimensiones) es mediante el "aplanado" (*flatten*) de la imagen. Por ejemplo, para el caso de una en escala de grises

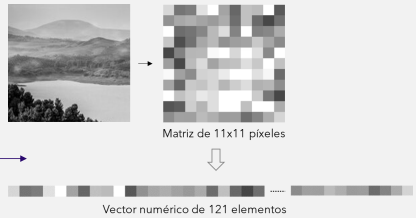

Este proceso puede ser aplicado también a imágenes a color. En este caso se representa cada imagen como un vector d-dimensional, donde d = número de píxeles de cada canal.

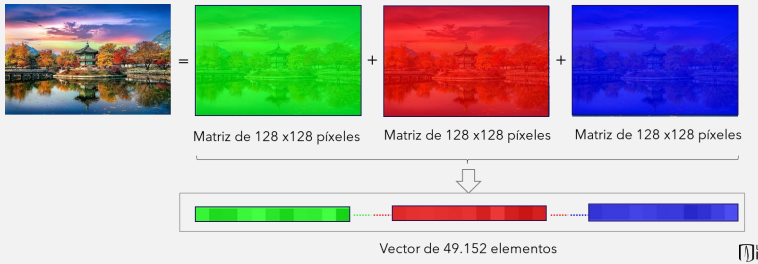

❑ Textos

Los textos son datos no estructurados.

Presentan alta variabilidad en vocabulario, longitud y forma de expresión.

El significado semántico no es explícito y depende del contexto.

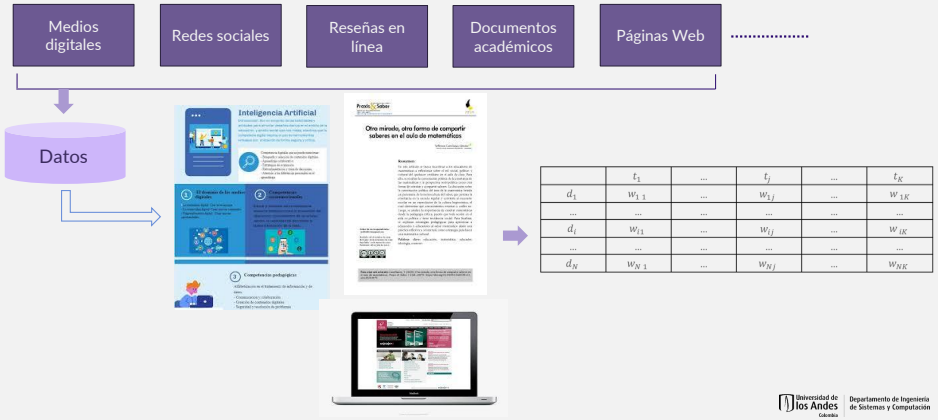

$$\begin{array}{c|cccccc} & t_1 & \dots & t_j & \dots & t_K \\ \hline d_1 & w_{1\,1} & \dots & w_{1\,j} & \dots & w_{1K} \\ \dots & \dots & \dots & \dots & \dots & \dots \\ d_i & w_{i1} & \dots & w_{ij} & \dots & w_{iK} \\ \dots & \dots & \dots & \dots & \dots & \dots \\ d_N & w_{N\,1} & \dots & w_{Nj} & \dots & w_{NK} \end{array}$$

Algunos sesgos en ML

1. Impacto desigual. los resultados de un sistema de AA suponen una desventaja desproporcionada para un grupo específico.	2. Trato desigual: cuando un modelo de AA trata a las personas de forma diferente en función de su pertenencia a un grupo protegido.	3. Preexistente o histórico: los datos del entrenamiento reflejan prejuicios o sesgos sociales existentes.	4. De muestra: los datos del entrenamiento no son representativos de la población a la que se supone que debe servir.	5. De medición: errores sistemáticos en la forma de recopilar o medir los datos.	6. De agregación: un modelo simplifica en exceso o no capta la diversidad dentro de un grupo.	7. De proxy: un modelo utiliza un atributo como sustituto de un atributo protegido.
Ocurre incluso cuando el atributo protegido no se incluye explícitamente en el modelo.	Implica un efecto discriminatorio directo.	El modelo aprende estos sesgos	Modelo funciona bien con datos de entrenamiento, pero mal con datos reales	Causa distorsión de datos de entrenamiento	Puede ocurrir cuando trata a subgrupos distintos como un grupo homogéneo.	Ejemplo: los códigos postales con proxy de la raza o el nivel de ingresos.
Ejemplo: raza, sexo, edad o religión.	El atributo protegido se utiliza explícitamente en el proceso de toma de decisiones.	Propaga los sesgos en sus predicciones.	Conduce a resultados injustos.	Hace que el modelo aprenda asociaciones incorrectas.	Puede llevar al modelo a generalizaciones incorrectas o injustas.	Da lugar a resultados sesgados incluso cuando no se utiliza directamente el atributo protegido.

❑Ejemplo: sesgo de muestra

- Los datos del entrenamiento **no son representativos** de la población a la que se supone que debe servir.
- Modelo funciona bien con datos de entrenamiento, pero mal con datos reales.
- Conduce a resultados injustos.

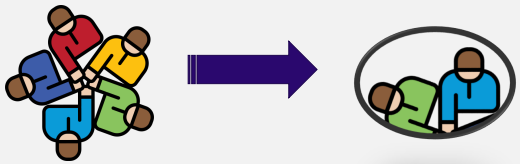

- **Proyecto**. Detección del uso correcto de tapabocas a partir de imágenes.

Análisis del problema

Objetivo. Facilitar el cumplimiento de uno de los protocolos más importantes para reducir el contagio de virus como el Covid – 19.

Propuesta. Utilizar técnicas de machine learning aplicado a imágenes con el fin de crear un modelo capaz de categorizar si una persona está usando correcta o incorrectamente un tapabocas, o si no lo está usando.

Tarea: detección de objetos.

Además, desplegar el modelo en una página web que capture la imagen de las personas y las clasifique según el uso adecuado, inadecuado o no uso de tapabocas, la cual podrá utilizarse para permitir el acceso a sitios, facilitar el aprendizaje para el correcto manejo del tapabocas, entre otros.

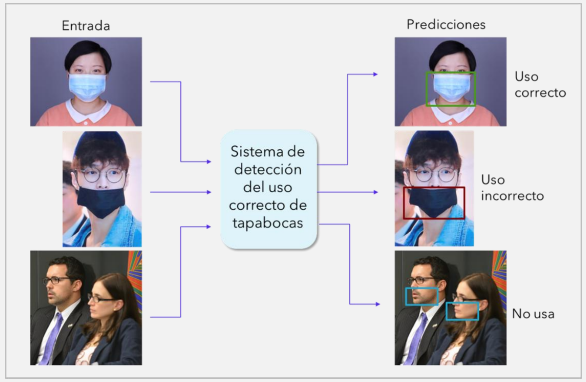

*Julián Montoya.

Datos

- Imágenes de personas sin y con tapabocas, tomadas de repositorios públicos (5 fuentes diferentes).
- Imágenes de caras de personas con simulación artificial de uso de tapabocas.
- En este punto se separó un conjunto de imágenes para el test.

Preparación de datos

- Remoción de imágenes con mucho ruido o que no representaban una cara.
- Corrección de etiquetas que no correspondían a la imagen.
- Aumentación de imágenes para obtener modificaciones de las imágenes existentes con el fin de crear un balance entre clases (sobre entrenamiento)

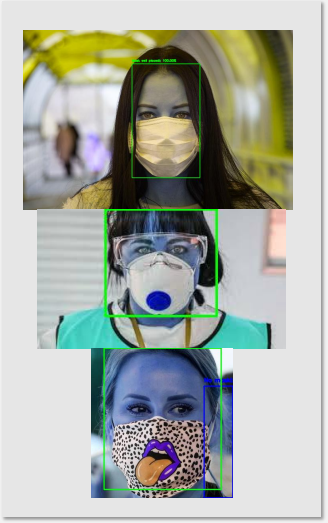

Modelado

- Modelo: red neuronal preentrenada (mobilnetV2).
- Aplicación de técnicas de selección de modelos para el ajuste de hiperparámetros.

Despliegue

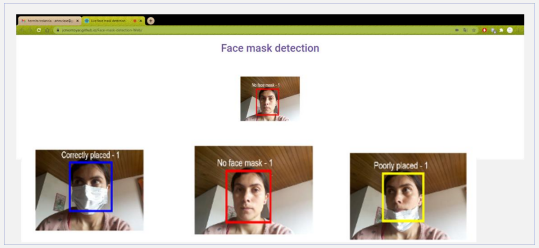

Evaluación

	precision	recall	f1-score	support
Mask_correcly_placed	0.95	0.97	0.96	1808
Mask_poorly_placed	0.76	0.71	0.73	212
No_face_mask	0.99	0.96	0.97	1177
accuracy			0.95	3197
macro avg	0.90	0.88	0.89	3197
weighted avg	0.95	0.95	0.95	3197

¿Qué pasó?

Sesgo de muestra

	Uso correcto de tapabocas	Uso incorrecto de tapabocas	No usa tapabocas
Asiático	3,602	368	91,921
Negro	1,064	67	1,888
Blanco	4,368	129	17,808

Colombianos -> F1score Macro 78%

❑ Analizar el siguiente caso

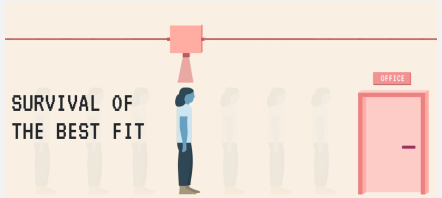

https://www.survivalofthebestfit.com/

Exploración de los datos

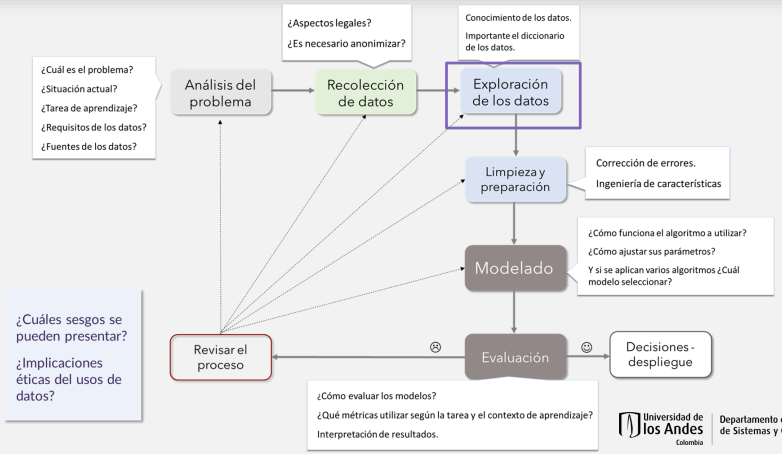

❑ ¿Cómo conocer los datos?

Comprensión de los datos

Análisis exploratorio

- Se obtiene un primer conocimiento de los datos.
- Proporciona información para determinar problemas de calidad en los datos.
- Ayuda a determinar si el conjunto de datos es adecuado para resolver el problema.
- Técnicas: perfilamiento de datos, gráficos (histogramas, diagramas de dispersión, diagramas de caja), análisis de correlación,...

Algunas preguntas ....

- *¿Cuál es la dimensión del conjunto de datos?*
- *¿Cuál es el significado de los atributos? ¿Cuál es el rango de valores permitido para cada variable?*
- *¿Existen valores ausentes? ¿Cómo se representan? ¿Con qué frecuencia se presentan?*
- *¿Existen valores fuera de rango? ¿Valores extremos?*
- *¿Los datos son completos? ¿Cubren todos los casos?*
- *Cuando los datos provienen de diferentes fuentes, ¿los significados de los datos son iguales? ¿Tienen la misma unidad de medida?*
- *¿Existen datos redundantes? ¿Datos duplicados?*
- *¿Los datos son consistentes con respecto al dominio del problema?*
- *¿Existen variables correlacionadas?*
- *¿Cuáles son las reglas para manejar los datos nulos?*
- *En un contexto de clasificación, ¿cuál es la proporción de las clases? ¿Los datos no están balanceados?...*

Referencias

Libro: Sinan Ozdemir (2024). Principles of Data Science. Packt Publishing.

- **Capítulo 2. "Types of data".**
- **Capítulo 13. "Mitigating Algorithmic Bias and Tackling Model and Data Drift “.**